Recomendación de secuencias: GRU4Rec

Patricio Cerda Mardini / Denis Parra

MIA
Sistemas Recomendadores

Contenidos

1. Definición del problema
2. Técnicas
3. Notebook
4. Extensiones
5. Referencias

Material suplementario

- **Repositorio**: /paxcema/KerasGRU4Rec/
- **Notebook**: Link a Google colab via
- **Ambiente**: Python3 + GPU
- Ejecutar todo ahora, demora un poco!

Contexto

Recomendación basada en sesiones para *e-commerce*.

¿Qué es una sesión?

- Usuario anónimo
- *Secuencia de clicks*: visitas orgánicas a distintos productos

Dataset: RecSys Challenge 2015

Usaremos el set de datos publicado para el desafío RecSys del 2015.

- Sesiones anónimas en *e-commerce* europeo grande (7 millones)
- Proveedor: empresa YooChoose - *outsourcing* de RS

En este caso, solo hay feedback implícito: si el usuario/sesión visitó al ítem, y cuándo:

Session	**Item**	**Timestamp**
1	25	5
1	34	10
1	17	15
2	98	18
...	...	...

RSC15 ofrece 31 millones de estos eventos.

¿Problema a resolver?

Next-item prediction

Dada una secuencia de items previamente visitados, predecir el siguiente item que el usuario verá.

En la práctica (*test time*), se recomienda la lista `top-N` predicha:

$$(25, 34) \rightarrow \ ?$$

$$? = [5, \mathbf{17}, 68, 99, 7]$$

Contenidos

1. Definición del problema
2. Técnicas
3. Notebook
4. Extensiones
5. Referencias

Trabajo previo

Item k-Nearest Neighbors

Matriz de similaridad: co-ocurrencia de ítems en base a clicks
Usa solamente el último click como prior

Markov Decision Process

$$< estados, acciones\ (recomendaciones), recompensas, transiciones >$$

Inmanejable si se incluye todas las posibles secuencias de acciones del usuario

General Factorization Framework

Usa info. pasada, pero no considera el orden de la secuencia

Framework: GRU4Rec

Influyente trabajo publicado en ICLR 2016.

SESSION-BASED RECOMMENDATIONS WITH RECURRENT NEURAL NETWORKS

Balázs Hidasi *
Gravity R&D Inc.
Budapest, Hungary
balazs.hidasi@gravityrd.com

Alexandros Karatzoglou
Telefonica Research
Barcelona, Spain
alexk@tid.es

Linas Baltrunas †
Netflix
Los Gatos, CA, USA
lbaltrunas@netflix.com

Domonkos Tikk
Gravity R&D Inc.
Budapest, Hungary
domonkos.tikk@gravityrd.com

Primera aproximación al problema mediante redes neuronales, con buenos resultados.

Recurrent Neural Networks

Tratan datos secuenciales

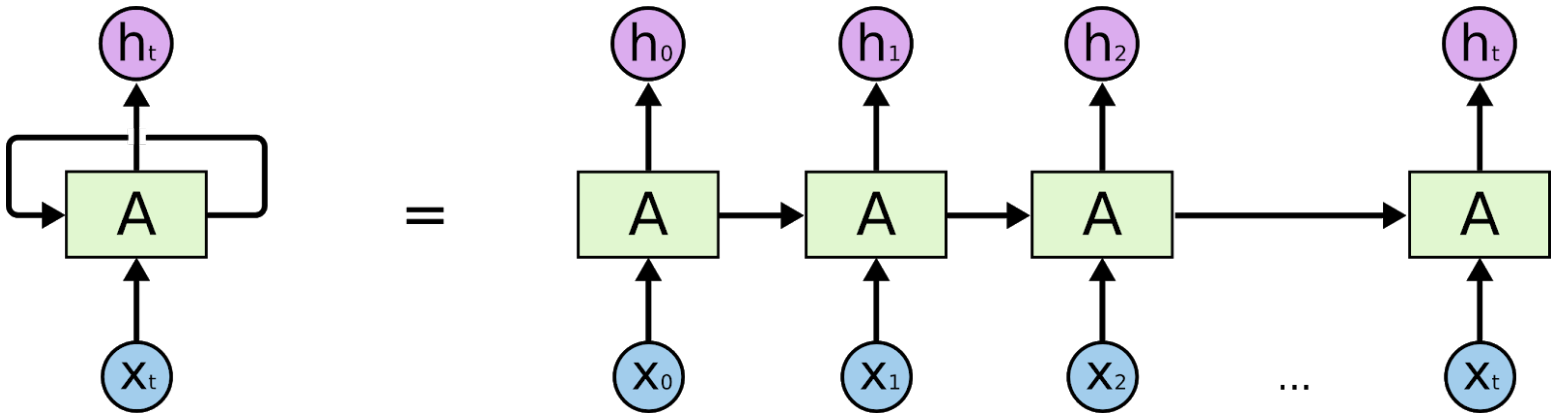

Recurrent Neural Networks

Arquitectura personalizable según tipo de entrada y salida

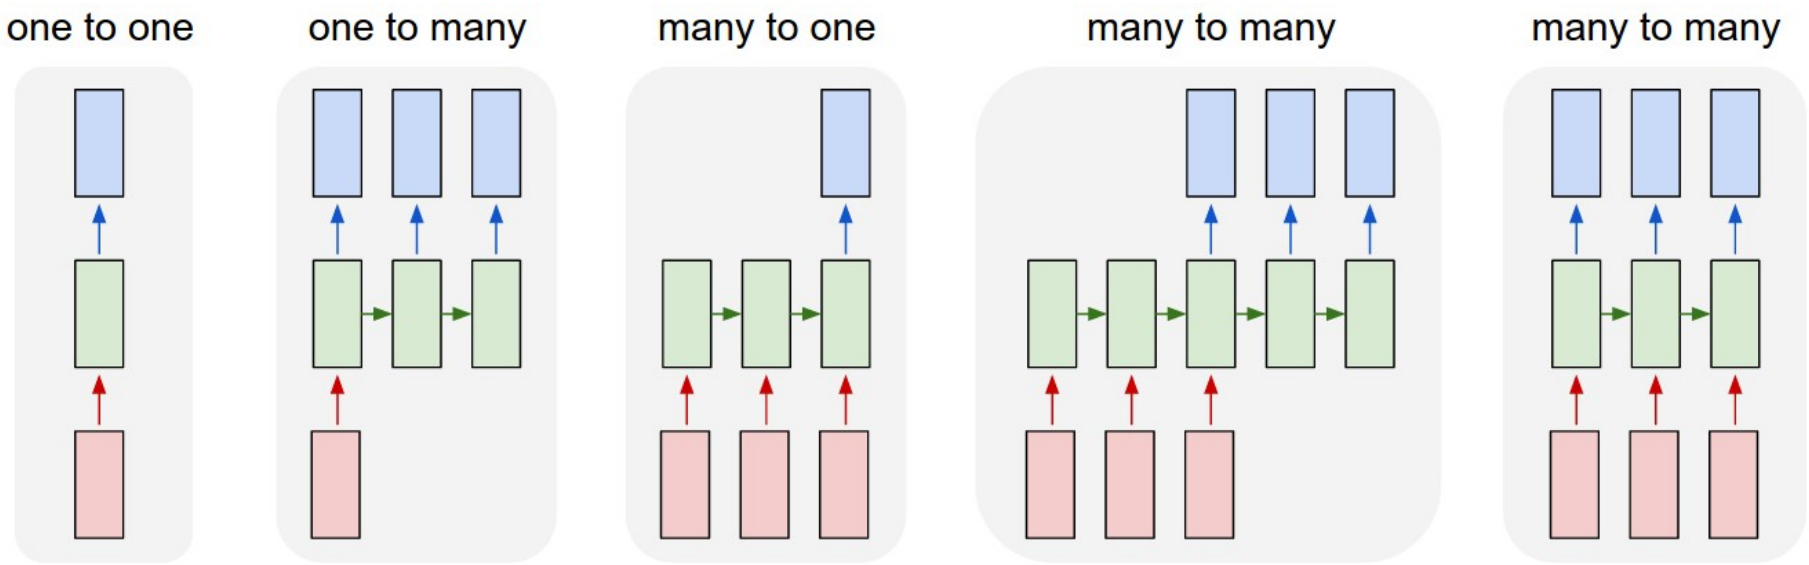

RNN: vanishing gradient

Aún cuando en teoría se puede, la arquitectura típica no es capaz de capturar dependencias de largo plazo.

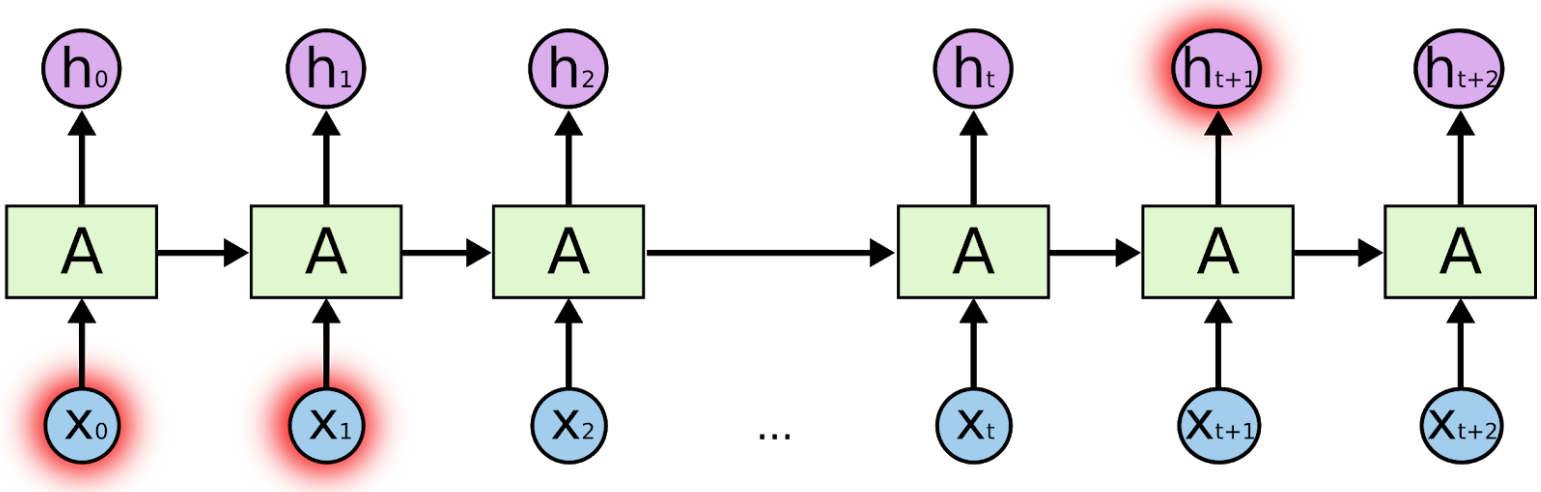

Gated Recurrent Units

Resuelven el problema del gradiente. Propuestas por Bengio et al. en 2014.

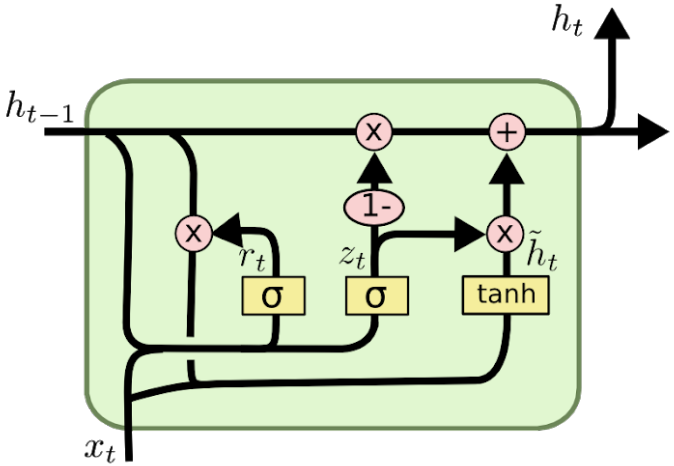

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

Permite recordar y olvidar, selectivamente, por intervalos indeterminados de tiempo. Gradiente no desaparece ni explota.

Entrena más rápido que una LSTM pues tiene menos parámetros.

¿GRU4Rec?

Idea: aprovechar dependencias de largo plazo en la sesión para mejorar las recomendaciones.

¿Qué pasa si un item visto hace muchos clicks es clave para sugerir algo que el cliente termine comprando? La GRU surge como opción.

Esto se extiende naturalmente si ahora tenemos cookies que nos permiten seguir a un usuario entre visitas distintas al portal de e-commerce.

GRU4Rec

Modelo neuronal muy simple. Procesa secuencialmente sesiones para predecir el siguiente item.

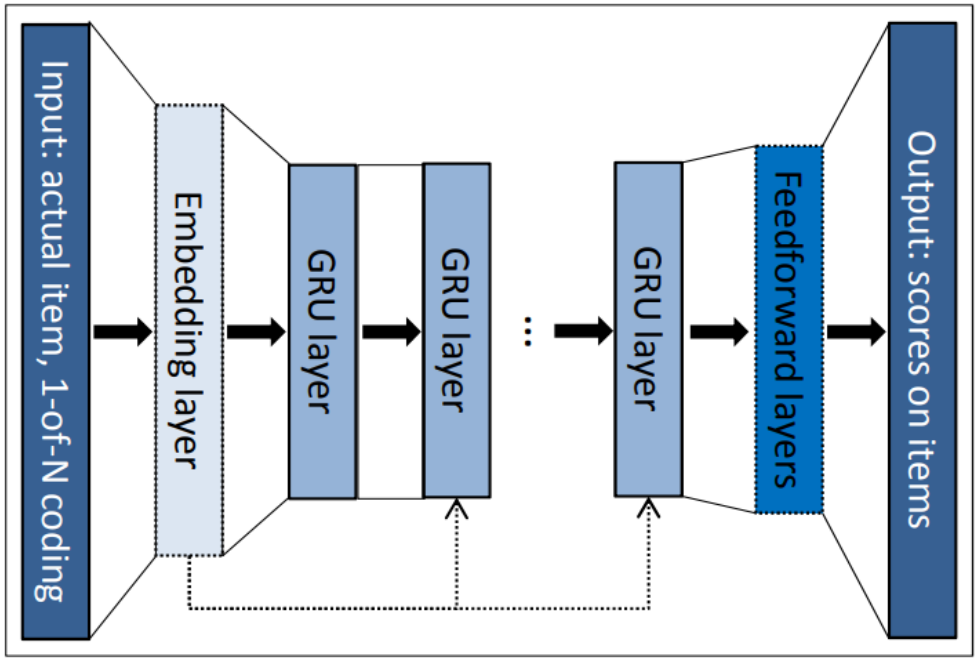

100 hidden units, dropout 0.5

GRU4Rec

En Keras:

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         (512, 1, 8725)            0
_________________________________________________________________
cu_dnngru_1 (CuDNNGRU)       [(512, 100), (512, 100)]  2648100
_________________________________________________________________
dropout_1 (Dropout)          (512, 100)                0
_________________________________________________________________
dense_1 (Dense)              (512, 8725)               881225
=================================================================
Total params: 3,529,325
Trainable params: 3,529,325
Non-trainable params: 0
```

Optimizador: ADAM, parámetros por defecto.

Función de pérdida: *cross-entropy*.

Modificación

Para entrenar eficientemente, se procesan sesiones en paralelo:

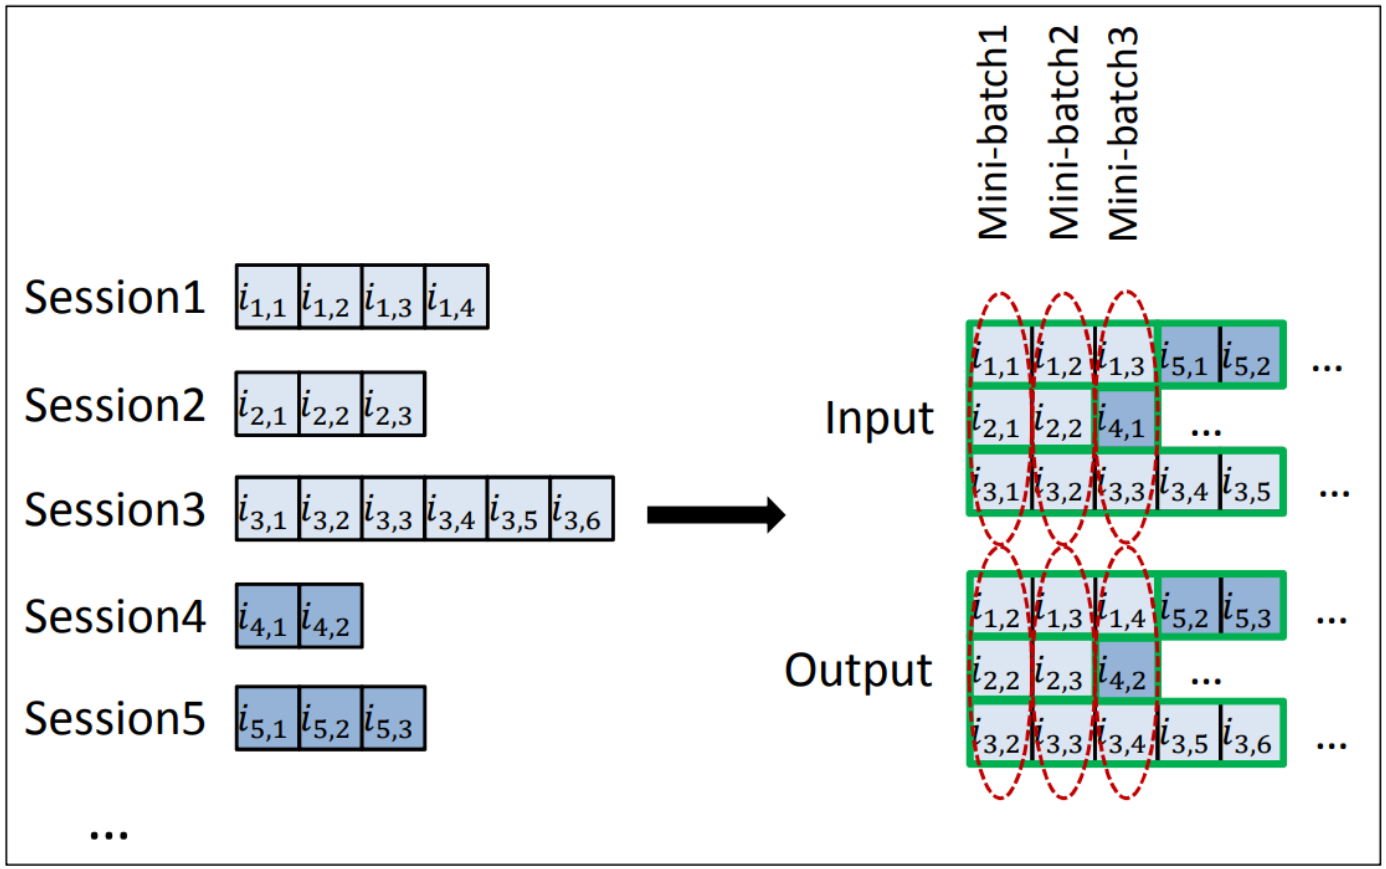

Notar que se analiza cada sesión por completo.

Algunas consideraciones

1. Se ordenan las sesiones
2. Para cada sesión, si el evento actual es t, el *target* es el evento siguiente $t + 1$
3. Al reemplazar una sesión finalizada por la siguiente, se resetea el estado oculto de la unidad GRU

Evaluación

Se utilizan dos métricas para evaluar el desempeño del sistema:

1. Recall @ 20
2. Mean Reciprocal Rank @ 20

$$\text{Recall} = \frac{\text{relevant items}}{\text{total items}}$$

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

Baselines

Los sistemas recomendadores contra los que los autores se comparan son:

1. Most Popular (POP)
2. Session Most Popular (S-POP)
3. BPR-MF

Resultados

Los resultados reportados en el paper son:

Method	**Recall@20**	**MRR@20**
POP	0.0050	0.0012
S-POP	0.2672	0.1775
BPR-MF	0.2574	0.0618
GRU4Rec	**0.5781**	**0.2375**

Contenidos

1. Definición del problema
2. Técnicas
3. Notebook
4. Extensiones
5. Referencias

Contenidos

1. Definición del problema
2. Técnicas
3. Notebook
4. Extensiones
5. Referencias

Loss functions

Aparte de *cross-entropy*, autores experimentan con otras familias de funciones de pérdida.

Las tipo *pairwise* comparan el ranking del *target* versus otros items. Las utilizadas en el paper original son BPR y Top1:

$$L_{\text{bpr}} = -\frac{1}{N_S}\sum_{j=1}^{N_S}\log\sigma(r_i - r_j) \qquad L_{\text{top1}} = \frac{1}{N_S}\sum_{j=1}^{N_S}\sigma(r_j - r_i) + \sigma(r_j^2)$$

Problema: *vanishing gradient*!

Loss functions

Solución: familia de funciones *pairwise max-ranking*. De la forma:

$$L_{\text{pairwise-max}}\left(r_i, \{r_j\}_{j=1}^{N_S}\right) = L_{\text{pairwise}}(r_i, \max_j r_j)$$

Modificaciones dan lugar a BPR_{max} y $Top1_{max}$:

$$L_{\text{bpr-max}} = -\log \sum_{j=1}^{N_S} s_j \sigma(r_i - r_j) \qquad L_{\text{top1-max}} = \sum_{j=1}^{N_S} s_j \left(\sigma(r_j - r_i) + \sigma(r_j^2)\right)$$

Resultados

Loss function	Recall@20	MRR@20
Cross Entropy	0.5781	0.2375
Top1	0.6117	0.2367
BPR	0.6322	0.2467
Top1Max	0.7086	0.3045
BPRMax	**0.7211**	**0.3170**

Se obtienen mejoras de un 23.2 % en R@20, y un 37.5 % en MRR@20.

Esto, con 2^{11} negative samples adicionales respecto al trabajo original.

Dwell Time

Podemos utilizar las *timestamp* en los datos para determinar el *Dwell Time*: cuánto tiempo permanece el usuario visitando cada item.

Supuesto

A mayor *Dwell Time*, más afinidad item-usuario hay

V. Bogina y T. Kuflik siguen esta idea en *"Incorporating Dwell Time in Session-Based Recommendations with Recurrent Neural Networks"*.

Item Boosting

Sea una sesión:

$$s_i = \{x_{i1}, x_{i2}, ...x_{in}\}$$

Cada item posee un *dwell time* dt_{ij}

Dado threshold[1] t, la sesión inflada queda:

$$s_i' = \{x_{i1} \cdot (1 + \frac{dt_{i1}}{t}), x_{i2} \cdot (1 + \frac{dt_{i2}}{t}), ... \ \ x_{in} \cdot (1 + \frac{dt_{in}}{t})\}$$

[1] t hiperparámetro. Autores usan $t = 75$.

Item Boosting

- Preprocesamiento sobre el *training set*

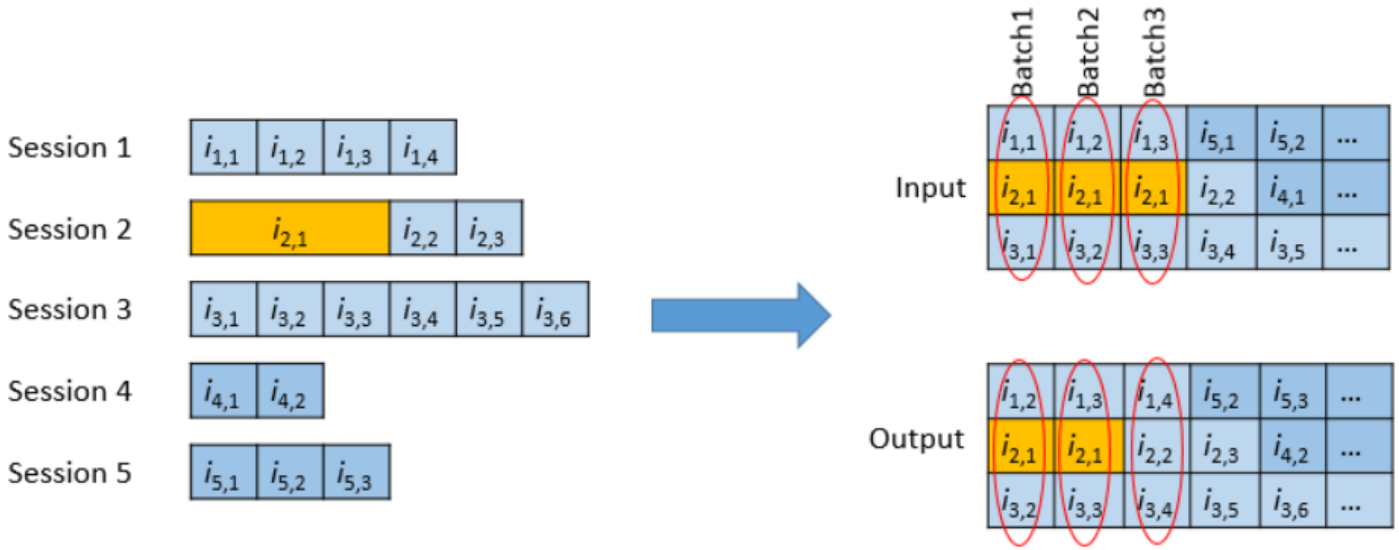

Resultados para RSC15

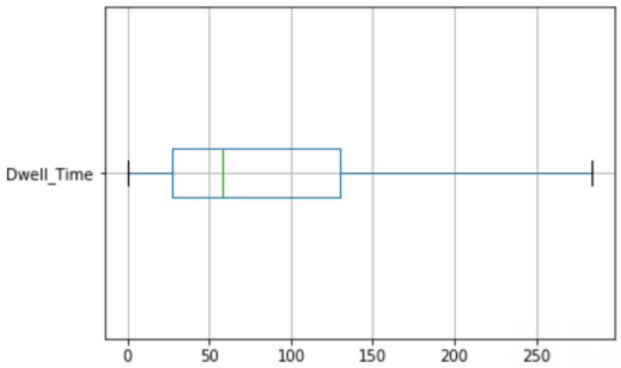

Figure 3. Boxplot with statistics on the data set's dwell time

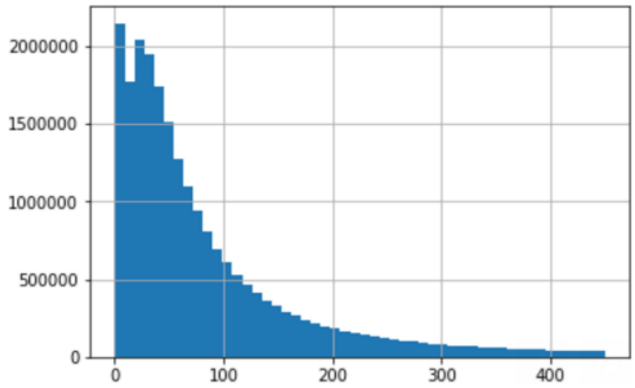

Figure 4. Dwell time distribution that is limited to items with dwell time less than 450 seconds.

Table 1. Comparison between different results

Method	recall@20	MRR@20
GRU4Rec [5]	*0.5853*	*0.2305*
GRU4Rec with dwell time threshold 75	0.7885	0.5834
GRU4Rec with dwell time threshold 100	0.7754	0.548
GRU4Rec with sampling [6]	*0.7117*	*0.308*
GRU4Rec with sampling and dwell time threshold 100	0.84	0.61
GRU4Rec with sampling and dwell time threshold 75	**0.853**	**0.636**

Conclusiones - GRU4Rec

- Las RNN son una gran herramienta para hacer recomendaciones
- Agnóstico al dominio: cualquier dataset de sesiones puede usarse
- Framework Keras permite rápida experimentación y prototipado

Otros modelos - Caser

Caser: Modelo basado en convoluciones.

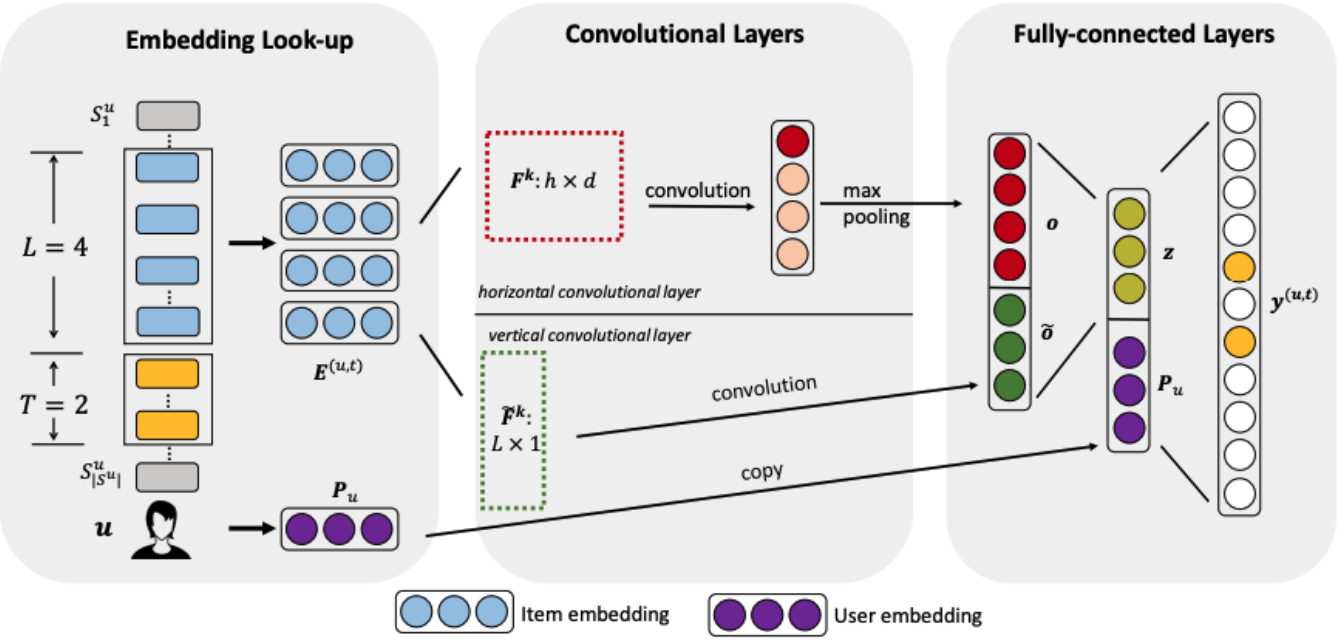

Figure 3: The network architecture of *Caser*. The rectangular boxes represent items $\mathcal{S}_1^u, \cdots, \mathcal{S}_{|\mathcal{S}^u|}^u$ in user sequence, whereas a rectangular box with circles inside stands for a certain vector *e.g.*, user embedding P_u. The dash rectangular boxes are convolutional filters with different sizes. The red circles in convolutional layers stand for the max values in each of the convolution results. Here we are using previous 4 actions ($L = 4$) to predict which items this user will interact with in next 2 steps ($T = 2$).

ref: Tang, J., & Wang, K. (2018). Personalized top-n sequential recommendation via convolutional sequence embedding. WSDM 2018.

Otros modelos - SASRec

SASRec: Modelo basado en Self-Attention

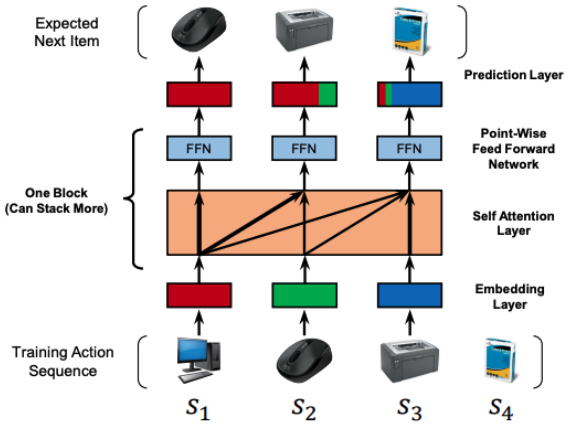

Figure 1: A simplified diagram showing the training process of SASRec. At each time step, the model considers all previous items, and uses attention to 'focus on' items relevant to the next action.

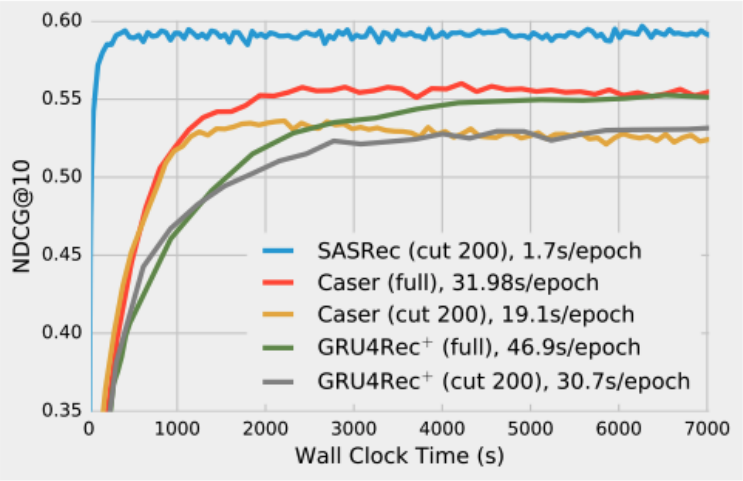

Figure 3: Training efficiency on *ML-1M*. SASRec is an order of magnitude faster than CNN/RNN-based recommendation methods in terms of training time per epoch and in total.

ref: Kang, W. C., & McAuley, J. (2018). Self-attentive sequential recommendation. In IEEE ICDM 2018.

Otros modelos - NextItNet

NexItNet: Modelo basado en Dilated Convolutions

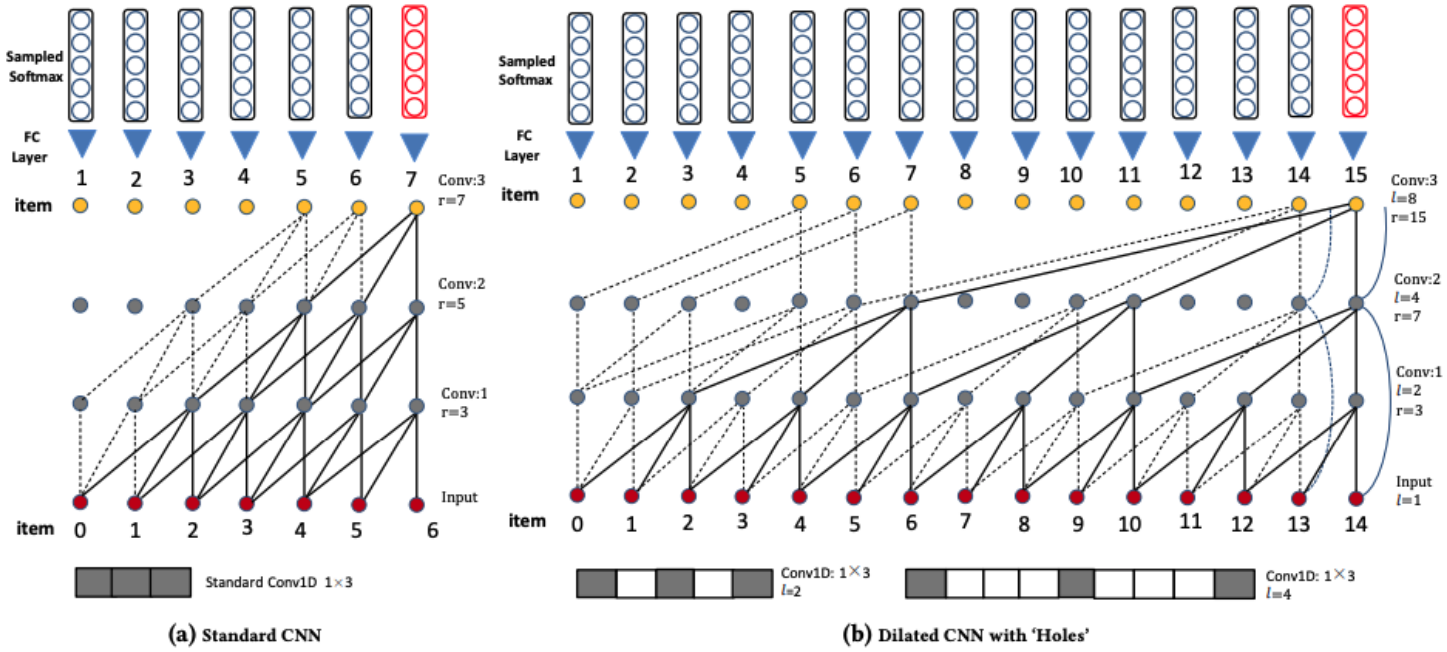

Figure 2: The proposed generative architecture with 1D standard CNNs (a) and efficient dilated CNNs (b). The blue lines are the identity map which exists only for residual block (b) in Fig. 3. An example of a standard 1D convolution filter and dilated filters are shown at the bottom of (a) and (b) respectively. We will refer to a dilated convolution with a dilation factor l as l-dilated convolution. Apparently, compared with the standard CNN that linearly increases the receptive field by the depth of the network, the dilated CNN has a much larger receptive field by the same stacks without introducing more parameters. It can be seen that the standard convolution is a special case of 1-dilated convolution.

ref: Yuan, F., Karatzoglou, A., Arapakis, I., Jose, J. M., He, X. (2019). A simple convolutional generative network for next item recommendation. WSDM 2019.

Contenidos

1. Definición del problema
2. Técnicas
3. Notebook
4. Extensiones
5. Referencias

Referencias

[1] Hochreiter, S. & Schmidhuber, J. Long short-term memory. Neural Comput. 9,1735–1780 (1997).

[2] Cho, K. et al (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation.

[3] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, Domonkos Tikk: Session-based recommendations with recurrent neural networks. ICLR, 2016

[4] Hidasi, B., & Karatzoglou, A. (2018). Recurrent Neural Networks with Top-k Gains for Session-based Recommendations. CIKM.

[5] Bogina, Veronika and Tsvi Kuflik. "Incorporating Dwell Time in Session-Based Recommendations with Recurrent Neural Networks." RecTemp@RecSys (2017).