A/B TESTING FOR RECOMMENDER SYSTEMS IN A TWO-SIDED MARKETPLACE

AUTORES Preetam Nandy, Divya Venugopalan, Chun Lo, Shaunak Chatterjee

04 Nov, 2025

PEDRO IRARRÁZAVAL, CRISTÓBAL MERINO, DIEGO SFEIR

ÍNDICE

01
CONTEXTO

02
PROBLEMA DE RECOMENDACIÓN

03
CONTRIBUCIÓN

04
ESTADO DEL ARTE Y MARCO TEÓRICO

05
DETALLE DE LA SOLUCIÓN

06
EVALUACIÓN

07
REFERENCIAS

01

CONTEXTO

CONTEXTO: A/B TESTING EN MERCADOS DE DOS LADOS

- Plataformas como LinkedIn, Amazon, Facebook → **two-sided marketplaces**.
- Evaluación clásica: A/B Testing (control vs. tratamiento).
- Comportamiento de un grupo de usuarios puede afectar directamente al otro.

Consumidor

Productor

En entornos donde los usuarios están interconectados, este método tradicional pierde validez.

02

PROBLEMA DE RECOMENDACIÓN

¿QUÉ SE RECOMIENDA?

- Grafo bipartito: consumidores ↔ productores
- El sistema recomienda ítems generados por productores.
- Cada consumidor recibe un ranking personalizado según relevancia.

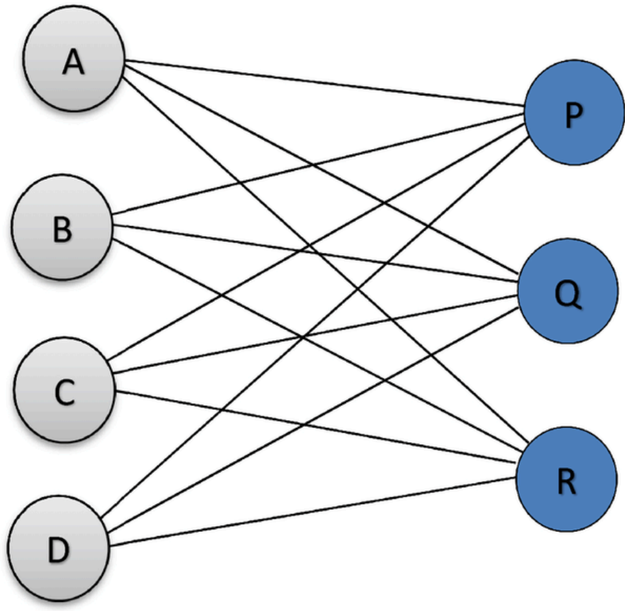

Grafo bipartito

REPRESENTACIÓN FORMAL

Para cada sesión s, el sistema recomienda un conjunto ordenado de ítems: $I_s \subseteq I$ donde cada ítem $i \in I_s$ pertenece a un productor.

¿CUÁL ES EL PROBLEMA EN EL A/B TESTING?

- Falla en el lado del productor

→ la exposición depende del grupo de sus consumidores

- Un mismo productor puede verse afectado por múltiples tratamientos al mismo tiempo, rompiendo la independencia necesaria para un A/B test válido.

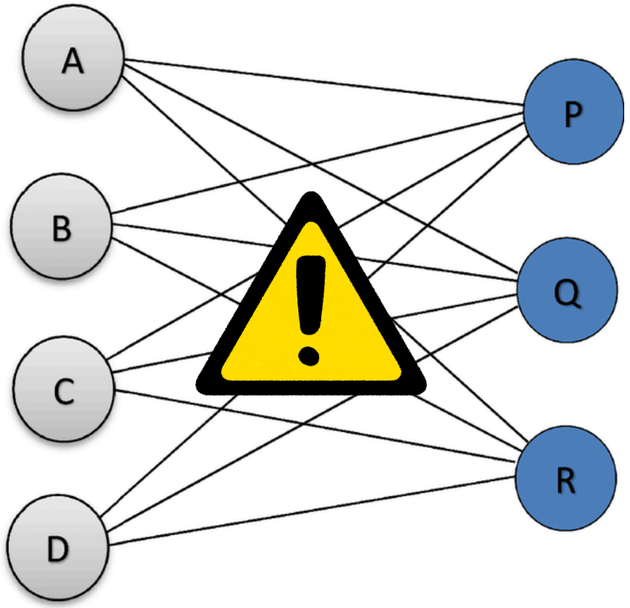

Grafo bipartito

03

CONTRIBUCIÓN

CONTRIBUCIONES PRINCIPALES

01

MECANISMO UNICORN

Unifica múltiples rankings contrafactuales.

02

MÉTRICA DE INEXACTITUD

Mide la calidad de un diseño experimental.

03

DEMOSTRACIÓN TEÓRICA

Prueba de optimalidad con límites de sesgo y varianza.

04

VALIDACIÓN EMPÍRICA

Simulaciones y aplicación real en LinkedIn a gran escala.

04

ESTADO DEL ARTE Y MARCO TEÓRICO

LIMITACIONES DEL A/B TESTING CLÁSICO

- A/B testing se basa en comparar los resultados entre grupos de control y tratamiento asumiendo SUTVA.
- En sistemas centrados en el consumidor esta suposición suele cumplirse, pero en los marketplaces de dos lados SUTVA se viola.

SUTVA

Stable Unit Treatment Value Assumption

MÉTODOS EXISTENTES PARA MEDIR EFECTOS EN MARKETPLACES

Método	Idea principal	Limitación
1. Aleatorización por clústeres de grafos	Agrupa nodos conectados y aplica el tratamiento por grupos.	Pierde precisión en redes densas.
2. Modelos de propagación del tratamiento	Simulan cómo el efecto se transmite entre nodos conectados.	Requieren conocer toda la red.
3. Métodos contrafactuales	Estiman qué pasaría si ciertos nodos recibieran o no el tratamiento.	Difícil de aplicar a gran escala.

UNICORN

- No necesita conocer la red
- No depende de su densidad
- Aplicable a redes reales y dinámicas
- Ajusta precisión ↔ costo computacional

05

DETALLE DE LA SOLUCIÓN

DEFINICIONES MATEMÁTICAS DEL DISEÑO EXPERIMENTAL

- $\mathbf{T_0, T_1, \ldots, T_k}$: modelos de recomendación (T_0 es control, los demás tratamientos).
- $\mathbf{P_0, P_1, \ldots, P_k}$: conjuntos de productores asignados a cada modelo.
- $\mathbf{p_k}$: fracción de productores en cada tratamiento ($\Sigma_k\, p_k = 1$).
- $\mathbf{I}$: conjunto total de ítems generados por los productores.
- $\mathbf{I_s \subseteq I}$: ítems mostrados en una sesión s de un consumidor.
- $\mathbf{R_k(i, I_s)}$: ranking del ítem i bajo el modelo T_k.
- $\mathbf{R^D(i, I_s)}$: ranking observado en el diseño experimental D.
- $\mathbf{R^*(i, I_s)}$: ranking ideal si cada productor se evaluara solo con su tratamiento.
- $\mathbf{N^D(i, I_s)}$: número de veces que un ítem se evalúa (costo computacional).

DEFINICIÓN 1: INEXACTITUD DEL DISEÑO

$$\mathbf{Inaccuracy(D) = E[(R^D(i, I_s) - R^*(i, I_s))^2]}$$

donde $R^*(i, I_s) = \Sigma_k\, R_k(i, I_s) \cdot 1\{i \in P_k\}$

DEFINICIÓN 2: COSTO COMPUTACIONAL

$$\mathbf{Cost(D) = E[N^D(i, I_s)]}$$

LADO DEL PRODUCTOR EN A/B TESTING EN MARKETPLACE BILATERAL

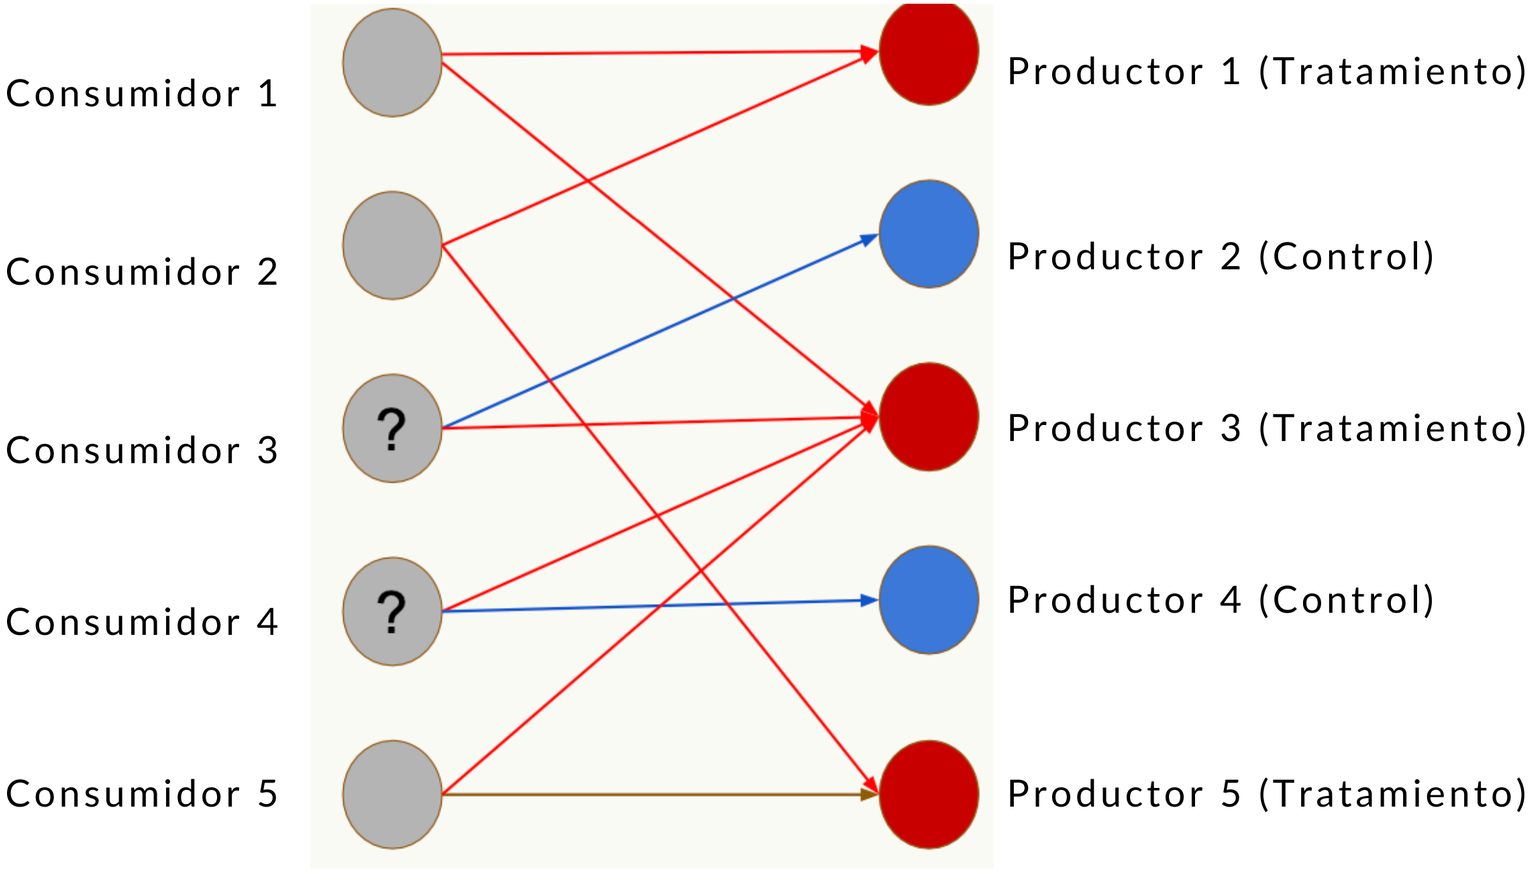

MECANISMO DE UNIFICACIÓN UNICORN

P1, P3, P5, P7: Productores grupo Control
P2, P4, P6, P8: Productores grupo Tratamiento

Ranking basado en Control (Modelo A):

P1	P2	P3	P4	P5	P6	P7	P8

Ranking basado en Tratamiento (Modelo A):

P1	P3	P4	P2	P8	P7	P5	P6

Ranking “ideal pero irrealizable” (R*)

P1		P3, P4	P2	P5, P8		P7	P6

Ranking con UniCoRn (Unifying Counterfactual Rankings) (R^D)

P1	P4	P3	P2	P8	P5	P7	P6

UniCoRn utiliza un mecanismo de score y reclasificación para romper empates

PSEUDOCÓDIGO ALGORITMO UNICORN

Entrada	Conjuntos de productores $\mathbf{P_0}$, $\mathbf{P_1}$, modelos de puntuación $\mathbf{T_0}$, $\mathbf{T_1}$, y parámetro de ajuste $\boldsymbol{\alpha}$.
Salida	Ranking unificado de ítems para cada sesión **s**.
Paso	**Descripción del código**
1	Para cada sesión con conjunto de ítems $\mathbf{I_s}$:
2	Obtener el ranking inicial $\mathbf{R_0(i, I_s)}$ según $\mathbf{T_0}$.
3	Construir $\mathbf{P_0^*}$ seleccionando aleatoriamente productores de $\mathbf{P_0}$ con probabilidad $\boldsymbol{\alpha}$.
4	Definir $\mathbf{I_{s,0}^*}$ y $\mathbf{I_{s,1}^*}$ como los ítems con productores en $\mathbf{P_0}$, $\mathbf{P_1}$ y $\mathbf{P_0^*}$ respectivamente.
5	Calcular las posiciones $\mathbf{L = \{R_0(i, I_s) : i \in I_{s,1} \cup I_{s,0}^*\}}$.
6	Obtener rankings $\mathbf{R_0}$ y $\mathbf{R_1}$ para los ítems $\mathbf{(I_{s,1} \cup I_{s,0}^*)}$** según los modelos $\mathbf{T_0}$ y $\mathbf{T_1}$.
7	Calcular el puntaje combinado:$\mathbf{rank_score(i) = R_0(i, \ldots) \cdot 1(i \in P_0^*) + R_1(i, \ldots) \cdot 1(i \in P_1)}$
8	Reordenar los ítems $\mathbf{(I_{s,1} \cup I_{s,0}^*)}$** en las posiciones **L** según **rank_score(i)** en orden ascendente (resolviendo empates al azar).

OTRAS VENTAJAS DE UNICORN

01 Optimalidad Teórica: El diseño es óptimo con respecto al error cuadrático medio (inexactitud).

02 Robustez Estadística: Proporciona límites de sesgo y varianza para la medición.

03 Escalabilidad: Puede manejar múltiples tratamientos de forma simultánea.

04 Tiene variantes costo-eficientes

VARIANTE DE UNICORN DE COSTO EFICIENTE

Mecanismo de ahorro:

1) Ranking Base: Se clasifican todos los ítems con el Modelo de Control (T0).

2) Fijar Posiciones: Se selecciona un subconjunto del Control y se fijan sus posiciones (quedan excluidos del proceso de mezcla).

3) Unificar Restantes: Se ejecuta UniCoRn(α) solo en los ítems restantes (los que no se fijaron)

- El parámetro α controla cuántos ítems se fijan vs cuántos se unifican

UniCoRn(α=0) - MÍNIMO COSTO	**UniCoRn(α=1) - MÁXIMA PRECISIÓN**
Versión más económica pero menos precisa	Versión más costosa (el UniCoRn original) pero más precisa

TRADE-OFF DE COSTO Y PRECISIÓN UNICORN

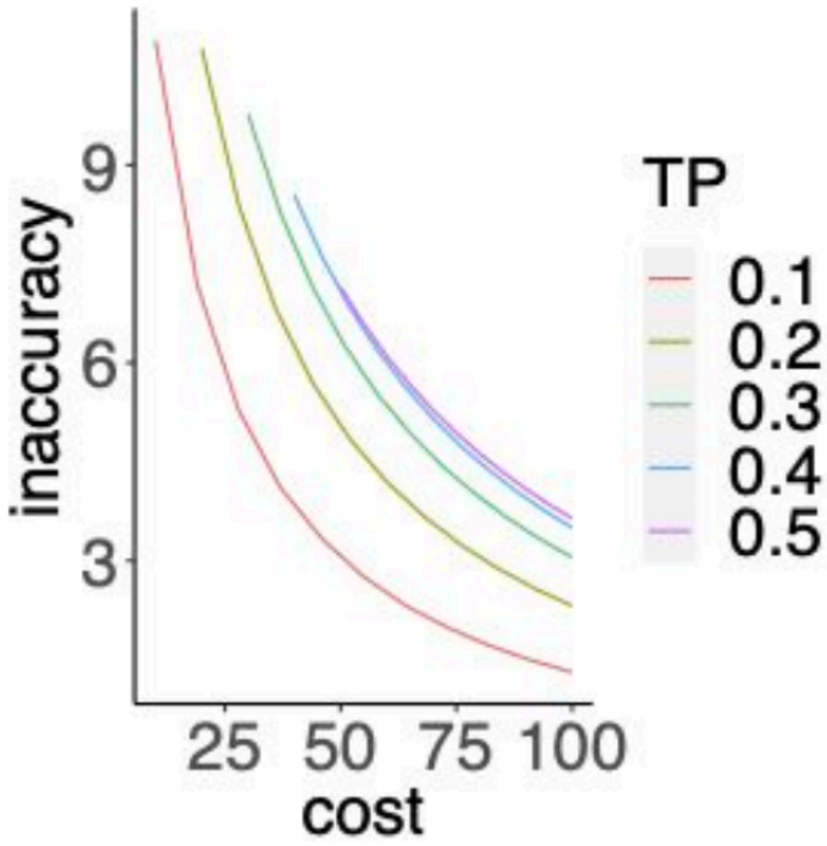

Para reducir el error, hay que pagar con velocidad (costo).

- Eje X (cost): Velocidad
- Eje Y (inacurracy): Error
- TP: Proporción de productores en Tratamiento
- Si el experimento es más difícil (TP alto), habrá más error, y mayor costo.

06

EVALUACIÓN

COMPARACIÓN CON MÉTODOS EXISTENTES

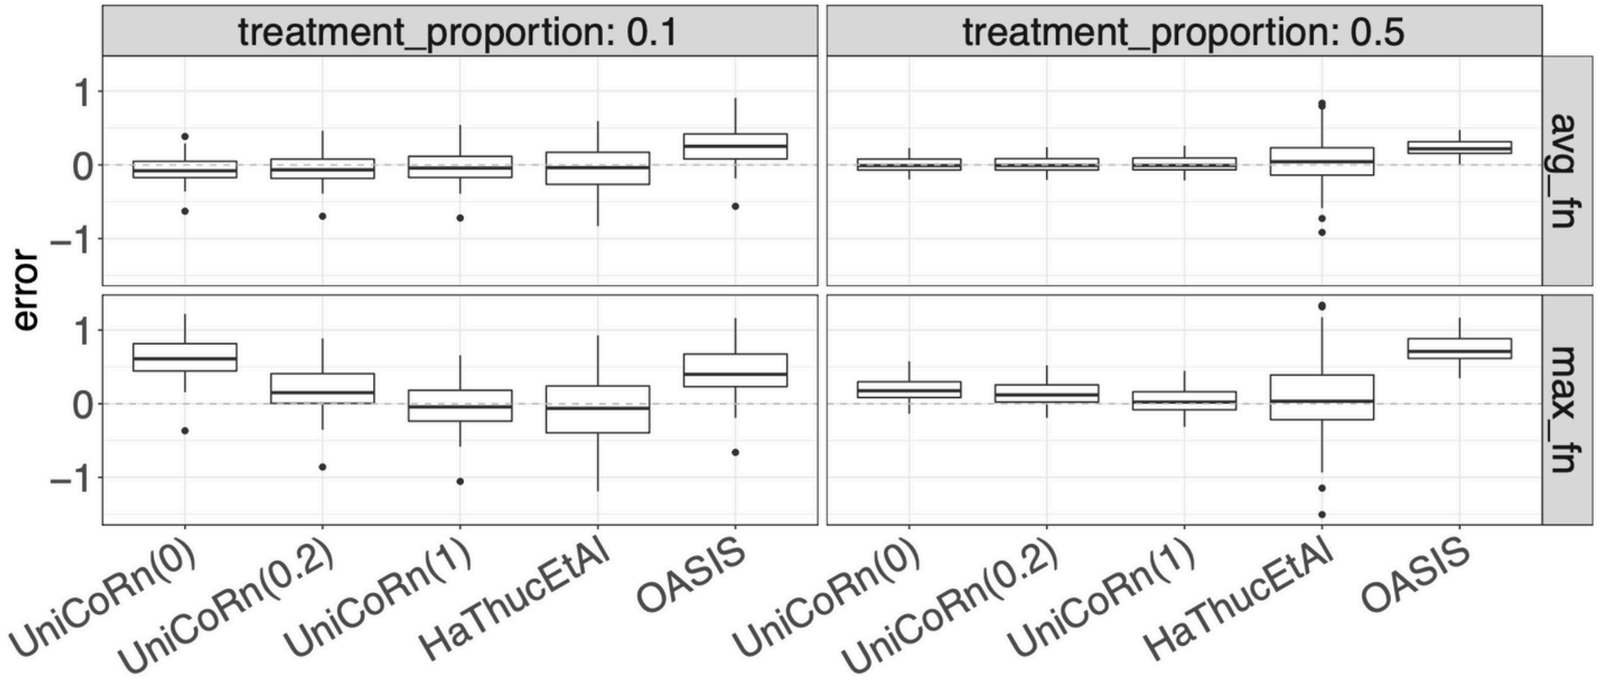

(4a) Errors in estimating the average treatment effect for two different rank to response functions and for two different values of the treatment proportion based on $N_S = 1000$ sessions with $L = 100$ slots each.

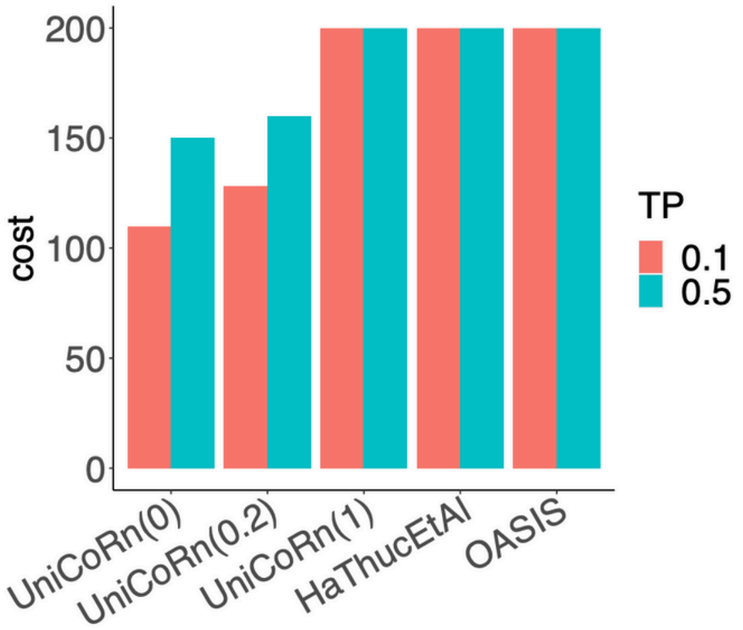

(4b) Hypothetical cost based on Definition 2 for treatment proportion (TP) equals 0.1 and 0.5.

COMPARACIÓN CON MÉTODOS EXISTENTES

- UniCoRn(1) se compara favorablemente con los métodos más avanzados
- UniCoRn(α) es más sensible a la elección de α con un TP = 0.1
- La función *max_fn* de ranking a respuesta es más sensible a la elección de α.
    - Deberíamos elegir un alfa (α) basado en la proporción de tratamiento y el tipo de función entre el ranking y la respuesta en nuestra aplicación.
- UniCoRn (0.2 o 0) proporciona una reducción de costo significativa si estamos dispuestos a sacrificar algo de precisión.

APLICACIÓN EN RED SOCIAL

- Se implementó UniCoRn en un sistema de recomendación de conexiones (*edge recommender*) en línea que atiende a decenas de millones de miembros y miles de millones de recomendaciones de conexiones diariamente.
- Los espectadores (*viewers*) como consumidores y las recomendaciones/receptores de vistas (*viewees*) como productores.
- En el experimento se tiene una proporción 50-50 de tratamiento y control en el lado del receptor/productor.
- Se eligió $\alpha=0$ (es decir, UniCoRn(0)) para minimizar el aumento de la latencia de puntuación (*scoring*) en línea.

APLICACIÓN EN RED SOCIAL

- **Experimento de generación de candidatos**: Para la generación de candidatos se utilizó la heurística del número de conexiones compartidas. Se probó una variante basada en una versión normalizada de las conexiones compartidas.

- **Experimento del modelo de ranking**: La etapa de ranking puntúa a todos los candidatos basándose en la asignación del modelo de los espectadores. Los modelos de ranking pueden ser modelos compuestos que optimizan los resultados del lado del espectador y/o del receptor de vistas. Uno de esos modelos de tratamiento optimizaba la retención del lado del receptor de vistas.

APLICACIÓN EN RED SOCIAL

- **Resultados estadísticamente significativos:**

Metrics	Delta % (candidate generation)	Delta % (ranking model)
Weekly Active Unique users	+0.51%	+0.13%
Sessions	+0.57%	+0.11%

Table 1: Viewee side impact of a new candidate generation model (with the same ranking model as control) and a new ranking model (with the same candidate generation model as control), measured with 40% viewer side traffic. All results are highly significant with p-value < 0.001.

  - Si la red subyacente es demasiado densa, los métodos basados en clústeres a menudo tienen dificultades para medir los experimentos estadísticamente.
  - Con esta técnica se pudo superar el problema de tener baja potencia (bajo poder estadístico).

CONCLUSIONES

- **UniCoRn es eficaz**: Su diseño proporciona un mecanismo para unificar múltiples rankings contrafactuales para facilitar las pruebas A/B del lado del productor.

- **UniCoRn es flexible**:
  - Ofrece un parámetro explícito para controlar la compensación (tradeoff) entre costo y precisión, lo que lo hace adecuado para aplicaciones a gran escala del mundo real.
  - Es agnóstico a la densidad o estructura de la red subyacente y no hace suposiciones sobre la propagación del efecto del tratamiento a través de la red.

- **UniCoRn ha demostrado un impacto en el mundo real.**

07

REFERENCIAS

REFERENCIAS

1. Nandy, P., Venugopalan, D., Lo, C., & Chatterjee, S. (2021). *A/B testing for recommender systems in a two-sided marketplace*. **In Advances in Neural Information Processing Systems** (NeurIPS 2021).
2. P. Nandy, K. Basu, S. Chatterjee, and Y. Tu. *A/B testing in dense large-scale networks: Design and inference*. **In Proceedings of the Thirty-fourth Conference on Neural Information Processing Systems** (NeurIPS 2020), 2020.
3. Y. Xu, N. Chen, A. Fernandez, O. Sinno, and A. Bhasin. *From infrastructure to culture: A/b testing challenges in large scale social networks*. **In Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**, pages 2227–2236, 2015.

A/B TESTING FOR RECOMMENDER SYSTEMS IN A TWO-SIDED MARKETPLACE

AUTORES Preetam Nandy, Divya Venugopalan, Chun Lo, Shaunak Chatterjee

04 Nov, 2025

PEDRO IRARRÁZAVAL, CRISTÓBAL MERINO, DIEGO SFEIR