ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Take a Fresh Look at Recommender Systems from an Evaluation Standpoint

Aixin Sun, 2023

IIC3633 Sistemas Recomendadores 2025-2

Grupo 10

Nicolás Bueno | Felipe Fuentes | Cristóbal Saravia

Contenidos

- Contexto.
- Problemas principales.
- Contribución.
- Marco teórico y estado del arte.
- Problemas de no incluir línea temporal global.
- Detalle de la solución.
- Resultados y conclusiones.
- Referencias.

Contexto

Contexto

- **Evaluación offline** de sistemas recomendadores: se utilizan una **variedad de métricas y métodos**, pero en muchas investigaciones estas métricas no se toma en cuenta la **dimensión temporal.**

- **Consecuencia:** no **considerar una línea temporal global** de las interacciones produce problemas en la evaluación y **resultados poco consistentes** que **no representan** fielmente el **rendimiento** de los modelos en un **ambiente real**.

Problemas principales

Problemas principales

En **evaluación offline** de sistemas de recomendación, los **splits train/test que no consideran la línea temporal global** de las interacciones pueden generar problemas:

- **Filtración de datos futuros** donde el modelo aprende información que en la práctica todavía no existe.
- **Sobre-simplificar las preferencias de usuarios** al **ignorar el contexto** de las interacciones usuario-ítem.

El baseline **Most Popular no considera la transitoriedad de la popularidad** de los ítems.

Problemas principales

Buscar una **respuesta a observaciones contraintuitivas** de investigaciones:

- ¿Por qué modelos entrenados solo con datos recientes tienen mejor desempeño que modelos entrenados con toda la data histórica?

- ¿Por qué usuarios con un historial más grande de interacciones obtienen peores recomendaciones?

Contribución

Contribución

Replantea la evaluación en sistemas de recomendación

En lugar de centrarse en qué modelo obtiene mejores métricas, se debe mirar cómo se evalúan esos modelos.

Estudios usan métodos de evaluación offline que ignoran el tiempo o mezclan datos pasados y futuros, lo que da resultados poco realistas.

Introduce el Timeline Scheme

Un método que organiza los datos cronológicamente y evalúa modelos por ventanas de tiempo (W), simulando cómo los sistemas funcionan online.

Contribución

Redefine la Fair Comparison

Los modelos pueden usar diferentes porciones temporales del conjunto de entrenamiento (ej. solo los datos recientes o los históricos), siempre que todos tengan acceso al mismo conjunto original

Propone una evaluación más realista de Popularidad

Define una Popularidad Reciente (Recent Popularity) que mida cuán popular fue un ítem en una ventana temporal específica.

Los rankings de popularidad (como los de Spotify o Netflix) se actualizan constantemente.

Marco teórico y estado del arte

Marco teórico

Evaluación offline: Se utilizan datos históricos ya registrados, sin la participación de usuarios reales

Evaluación online: Evalúa los modelos directamente en el sistema con usuarios reales comparando diferentes versiones del recomendador

Contexto de decisión: Las preferencias del usuario dependen del momento y de las alternativas disponibles. Dos usuarios pueden elegir el mismo ítem, pero bajo condiciones muy diferentes.

Línea temporal global: Implica ordenar todas las interacciones usuario-ítem según su timestamp real. Esto logra una evaluación más coherente y representativa de cómo se generan las recomendaciones en entornos online

Estado del arte

Desde los **primeros estudios** (Gunawardana & Shani, 2009) la **evaluación se centra en métricas** de ranking. Los enfoques de evaluación más usados (random split, leave-one-out) ignoran la cronología de las interacciones.

Esto genera un problema conocido como **data leakage**, donde los modelos acceden a información del futuro, obteniendo resultados artificialmente buenos.

Estudios recientes (Ji et al., 2022; Sysko-Romańczuk et al., 2023) muestran **resultados contraintuitivos** que evidencian fallas metodológicas. En la investigación académica se usan datasets estáticos que cubren largos periodos (ej. MovieLens, Amazon Reviews).

En la industria (Google, ByteDance) los modelos se actualizan continuamente con datos recientes. Surge necesidad de una evaluación offline que **respete la línea temporal** global y simule mejor los entornos reales online.

Estado del arte

Modelos recientes buscan incorporar factores contextuales

Sequential Recommenders o Context-Aware Models, son enfoques que usan secuencias de interacciones o variables externas (hora, ubicación, dispositivo) para capturar cambios en las preferencias.

La mayoría no considera una línea temporal global, tratando el tiempo solo como una feature más y no como una estructura del modelo

No modelan el "contexto de decisión", es decir, las alternativas disponibles y el entorno del usuario al momento de elegir

Esta omisión contribuye a la **simplificación excesiva de las preferencias** y resultados poco realistas

Sun, 2023

Estado del arte

Análisis sobre los articulos presentados en la conferencia ACM RecSys (2020 - 2022)

Table 2: Number and percentage of papers by their adopted data split scheme in ACM RecSys conference (2020 - 2022).

No. and % papers		Data split	Global timeline
30	34.1%	Random split	No
22	25.0%	Leave-one-out	No
17	19.5%	Single time point	Partially
15	17.0%	Simulation-based online	Yes
4	4.5%	Sliding window	Yes

Problemas de no incluir línea temporal global

Problemas de no incluir línea temporal global

Problema con Most Popular

Filtración de datos

Sobre-simplificación de las preferencias

Problema con Most Popular

- El baseline **Most Popular** utilizado en evaluaciones offline **no toma en cuenta** la **naturaleza transitoria de la popularidad** en contextos reales.

- **Ejemplos:**

  - **New York Times best sellers:** actualizados cada semana.
  - **Amazon best sellers:** actualizados cada hora.

The New York Times Best Sellers: https://www.nytimes.com/books/best-sellers/
Amazon best sellers: https://www.amazon.com/bestsellers

Problema con Most Popular

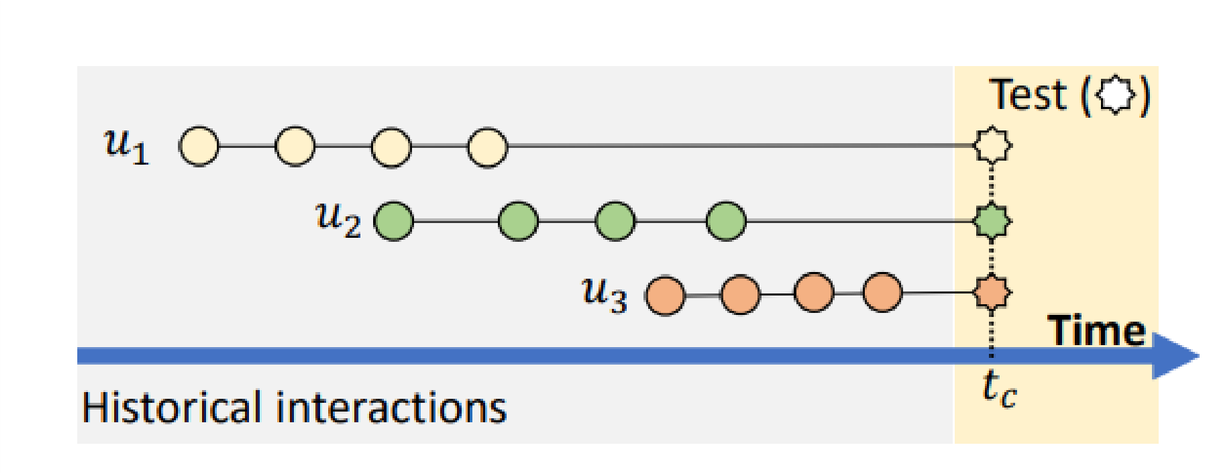

- Al no haber una ventana de tiempo para obtener los ítems más populares, el método **utiliza todas las interacciones del set de entrenamiento para obtener el ranking**.
- Para un dataset con un intervalo pequeño de tiempo, esto nos puede dar un buen indicador de popularidad.
- Sin embargo, este método **ignora la transitoriedad de la popularidad de los ítems** para datasets con interacciones que abarcan **largos periodos de tiempo** como MovieLens 20m, que abarca desde 1995 hasta 2015, por ejemplo.

Problema con Most Popular

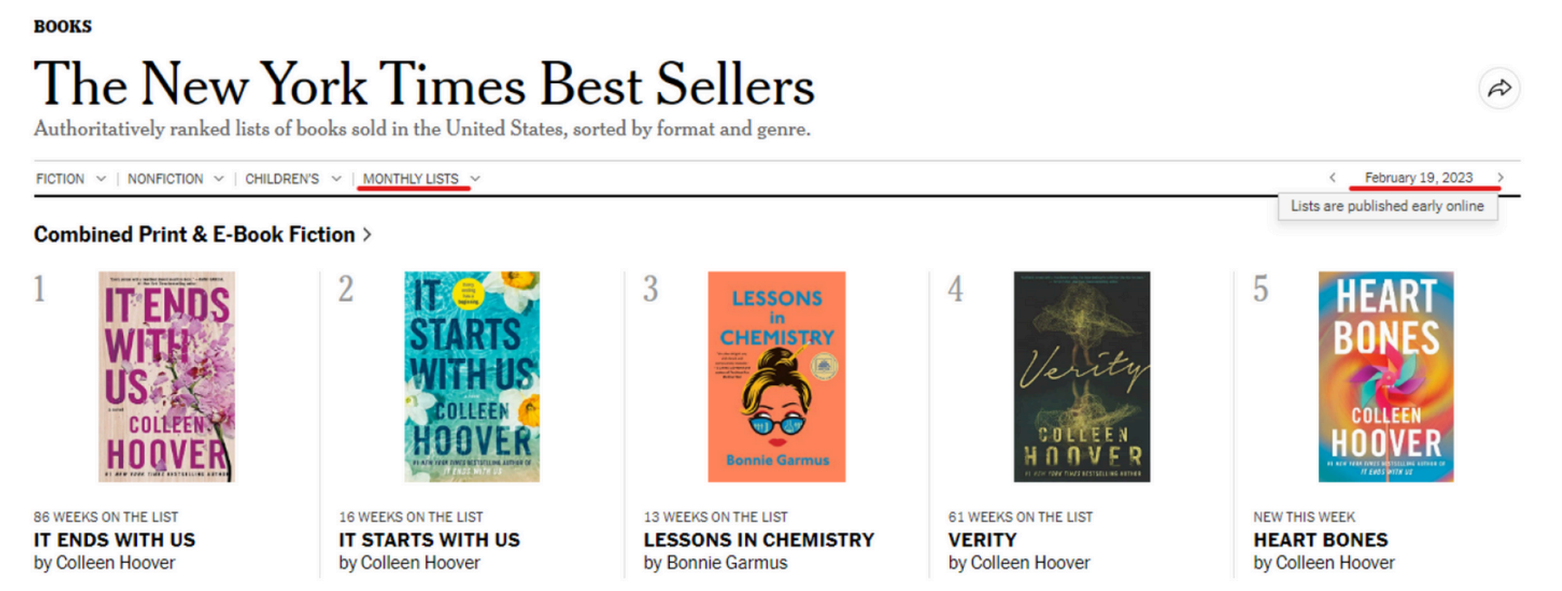

En el paper "A Re-visit of the Popularity Baseline in Recommender Systems" de Ji. et al. se reporta que, al **utilizar métodos de popularidad que entregan más valor a interacciones recientes** que antiguas, se obtiene una **mejora de más de 70% en métricas de predicción** comparado con Most-Popular en el dataset MovieLens 20m.

Sun, 2023

Filtración de datos

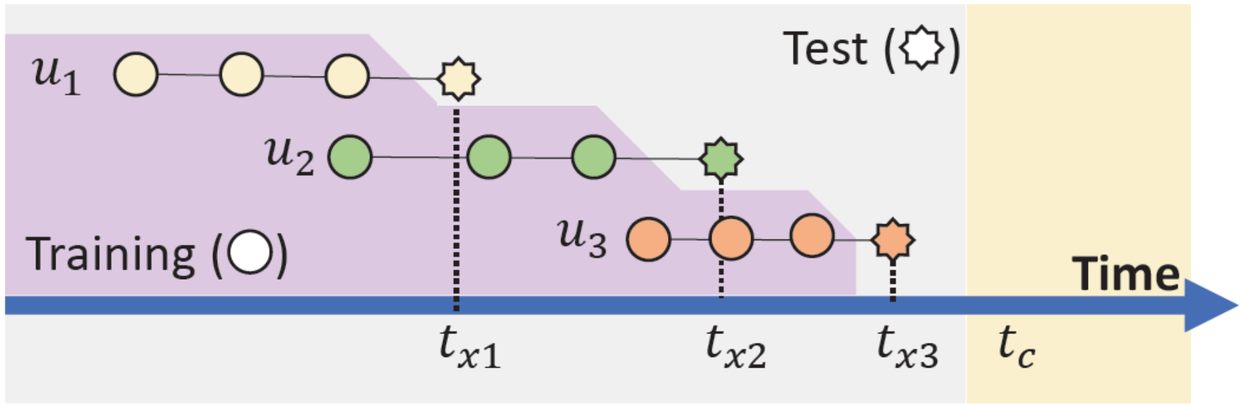

Figure 3: Train/test with leave-one-out split

Con los splits **Random** y **Leave-one-out** se puede dar una situación donde, para predecir una interacción, el modelo tiene información irrealista respecto a las interacciones de otros usuarios.

Al no tomar en cuenta el eje temporal para el set de entrenamiento, el **modelo en su evaluación offline puede tener información del futuro** para las predicciones, lo cual sería imposible en el contexto online real.

Filtración de datos

Digamos que el historial del **usuario u_1** termina en el **tiempo t_i** y queremos entregar una recomendación para ese tiempo con el split **Leave-one-out**:

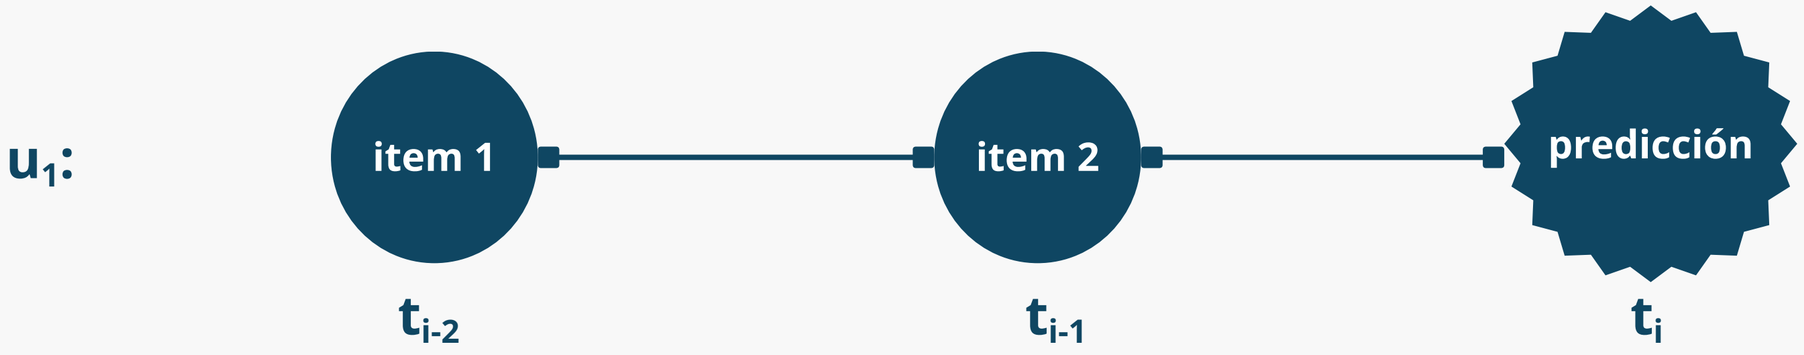

Pero, en nuestro **set de entrenamiento** el ítem **más popular** en el tiempo t_i es el **ítem k**.

Filtración de datos

El baseline **Most Popular recomendaría** el **ítem k** al **usuario u_1**, cuando para esta predicción **no debería tener conocimiento** de que será el más popular en el tiempo **t_i**.

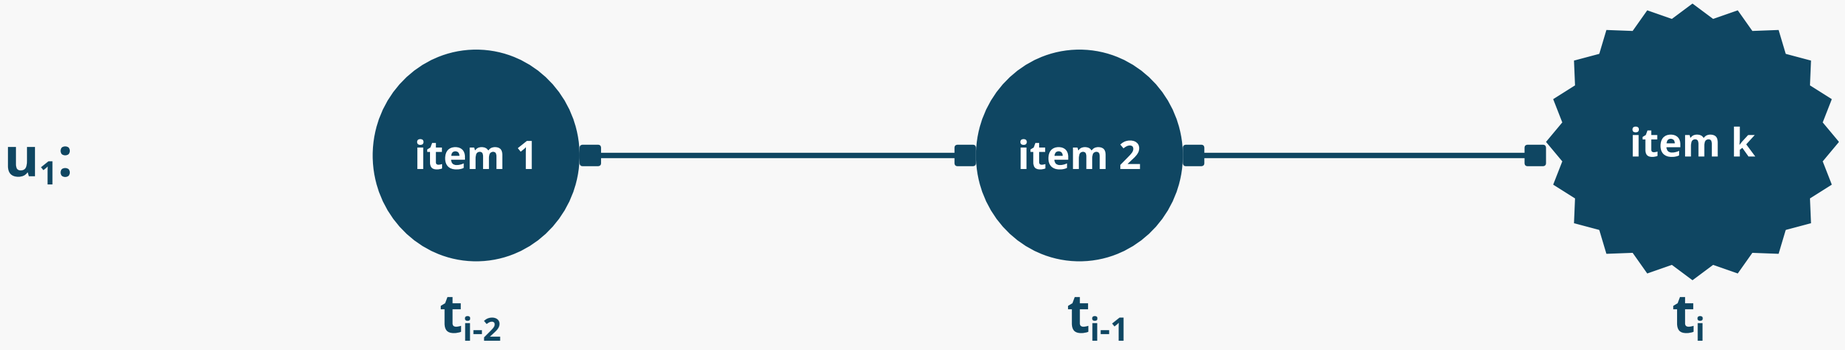

Modelos entrenados con este split podrían obtener buenas métricas de performance, no porque sean buenos capturando los patrones de las interacciones entre usuarios, sino que porque **se entrenan con información futura** que hace que sea muy fácil predecir las interacciones. Esto hace que las métricas de performance offline no sean siempre un buen reflejo del desempeño del modelo en el contexto online.

¿Por qué se evalúan de esta manera?

- Se espera que los **modelos sean comparados de manera "justa".**
- El baseline de popularidad y los modelos deben ser **evaluados con los mismos splits de entrenamiento-testeo**.
- Pero debido a la **filtración de datos** mencionada anteriormente, los **resultados se vuelven incomparables**, ya que un split que no considera el tiempo puede generar sets de entrenamiento con mucha o poca corrupción de datos futuros.

Modelo A

NDCG@10: 0.9

Datos de entrenamiento con mucha corrupción

Modelo B

NDCG@10: 0.6

Datos de entrenamiento con poca corrupción

Sobre-simplificación de las preferencias

Todavía no tenemos una respuesta para las observaciones contraintuitivas de "¿Por qué usuarios con historiales más grandes reciben peores recomendaciones?" y "¿Por qué modelos entrenados solo con datos recientes obtienen mejores resultados?"

Una **posible respuesta** puede ser la **sobre-simplificación de las preferencias de los usuarios** en los modelos al no tomar en cuenta el contexto de las interacciones.

Sobre-simplificación de las preferencias

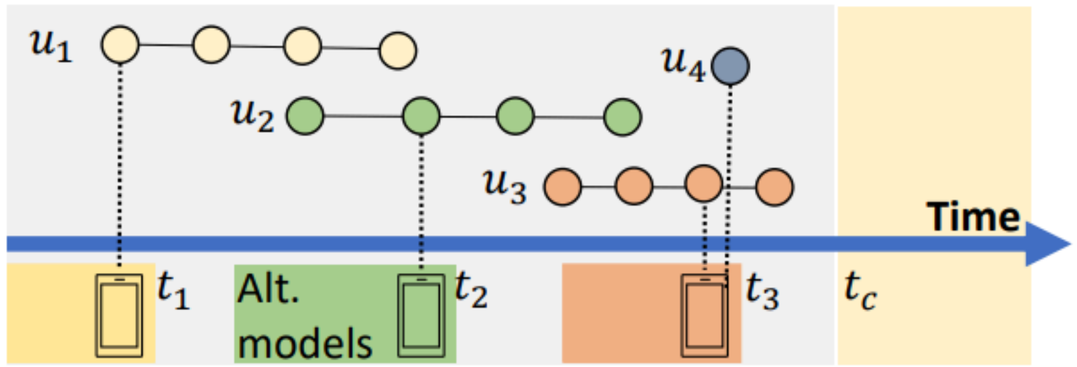

Figure 5: Context for decision making of an interaction *e.g.*, phone purchase

Interacciones de usuarios con el mismo ítem **pueden variar mucho en contexto en un periodo de tiempo largo**. Utilizar todas las interacciones en el tiempo para medir la **similitud** entre las **preferencias de usuarios** deja ser representativo cuando el intervalo de tiempo es grande, ya que las razones de la interacción pueden ser muy diferentes.

Sun, 2023

Sobre-simplificación de las preferencias

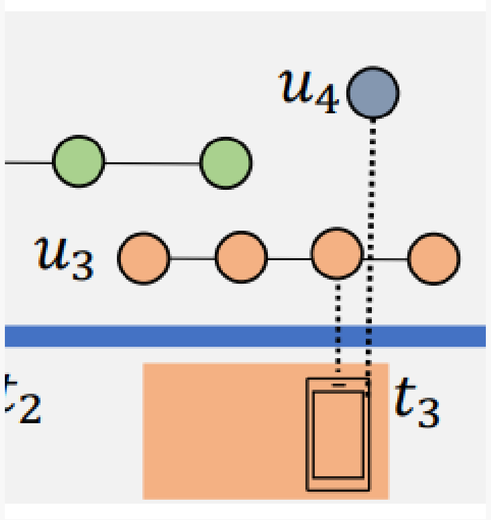

Usuarios u_3 y u_4 tienen más probabilidad de compartir sus razones para comprar el producto

Si se utilizan **interacciones más cercanas temporalmente**, es más probable que los **contextos de esas decisiones sean similares**. Esto podría explicar por qué los **usuarios con interacciones más recientes** reciben **mejores recomendaciones** y por qué utilizar **datos más recientes** e ignorar datos históricos puede entregar **mejor resultados**.

Sun, 2023

Sobre-simplificación de las preferencias

- **¿Por qué la industria no toma esto en cuenta en sus modelos?**
- Las **grandes empresas deben procesar muchos datos** constantemente tal que el número interacciones recientes tienden a ser suficiente para entrenar un modelo.
- Los **modelos de recomendación** en el contexto industrial son **re-entrenados con nuevos datos constantemente**. Para entrenamiento online, los modelos se adaptan en tiempo real al feedback de los usuarios.
- El **objetivo de las evaluaciones offline** suele ser **filtrar métodos** de recomendación que no sean apropiados y conseguir un subconjunto más pequeño de algoritmos **para testear en un ambiente online**. Entonces, en ciertos casos no entrega mucho valor tomar en cuenta la cronología.

Detalle de la solución

Detalle de la solución

Timeline Scheme

- Es un **esquema de evaluación offline** que incorpora la **línea temporal global** (global timeline) dividiendo la cronología de interacciones usuario-ítem en **ventanas de tiempo.**

- **Objetivo:** mitigar el problema de **filtración de datos** (data leakage)**,** y que el entrenamiento y evaluación de los modelos sea más realista.

Detalle de la solución

Timeline Scheme: pasos de funcionamiento

1. Se **ordenan todas las interacciones** usuario–ítem (de entrenamiento y testeo) por su **timestamp**.

2. Las interacciones se **dividen en ventanas de tiempo** consecutivas W_1, W_2, W_3,...

3. En cada ventana, el **modelo** se:

- **3.1. Entrena** con **interacciones pasadas,** de ventanas anteriores.
- **3.2. Evalúa** con **interacciones de testeo presentes,** de la ventana actual.

4. Luego el modelo **se actualiza/re-entrena** para la siguiente ventana.

Detalle de la solución

Timeline Scheme

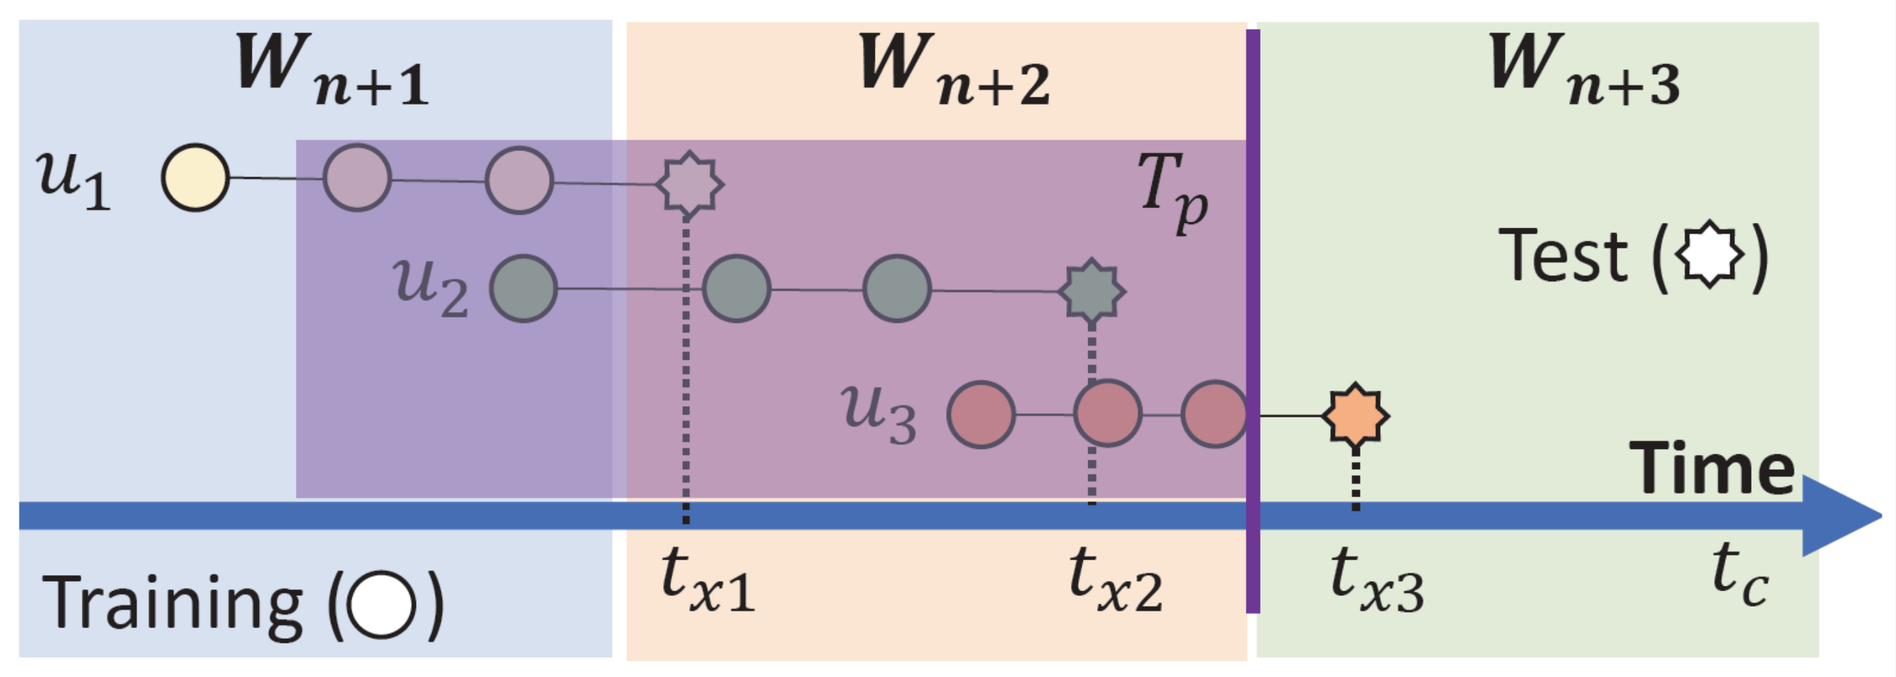

Ventanas de tiempo: W_n Usuarios: u_i

Timestamp de interacciones de testeo del usuario "i": t_{xi}

Detalle de la solución

Recent Popularity

- **Solución propuesta** al problema del método **Most Popular**:
  - "**Recent Popularity"** redefine la popularidad considerando solo **interacciones recientes** dentro de una **ventana temporal límite** al calcular el ranking de popularidad .
- Por ejemplo: top 10 ítems más populares durante la última semana.
- **Beneficio**: refleja la popularidad real en el momento de la recomendación y permite comparaciones más justas entre modelos.

Detalle de la solución

Inclusión de contexto en modelamiento de preferencias

- Se propone un **cambio de enfoque**: modelar las **preferencias** del usuario **considerando contexto temporal** y de **decisión**.

- **Objetivo:** representar de forma **más realista** las **preferencias** del usuario, considerando que las **interacciones dependen del contexto** temporal y situacional en que ocurren.

Resultados
y
conclusiones

Resultados y conclusiones

- En la mayoría de estudios se **ignora la línea temporal global** de interacciones usuario-ítem al **evaluar modelos offline**.
- Produce **problemas** de **filtración de datos** y **sobre-simplificación de preferencias** de usuarios.
- **Evaluaciones poco realistas**: no reflejan con precisión las decisiones de usuarios en escenarios reales.
- **Solución**: **Timeline Scheme**, e incorporar **contexto temporal y de decisión** al modelar preferencias.
- Permite **mitigar problemas** y realizar **evaluaciones más representativas** de la realidad.

Referencias

Amazon. (s. f.). Amazon´s bestsellers. Obtenido el 1 de noviembre de 2025, de https://www.amazon.com/bestsellers

Gunawardana, A., Shani, G., & Yogev, S. (2022). Evaluating recommender systems. In F. Ricci, L. Rokach, & B. Shapira (Eds.), Recommender systems handbook (3rd ed., pp. 547–601). Springer US. https://doi.org/10.1007/978-1-0716-2197-4_15

Ji, Y., Sun, A., Zhang, J., & Li, C. (2020). A re-visit of the popularity baseline in recommender systems. In Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’20) (pp. 1749–1752). Association for Computing Machinery. https://doi.org/10.1145/3397271.3401233

Ji, Y., Sun, A., Zhang, J., & Li, C. (2022). Do loyal users enjoy better recommendations? Understanding recommender accuracy from a time perspective. In Proceedings of the 2022 ACM SIGIR International Conference on Theory of Information Retrieval (ICTIR ’22) (pp. 92–97). Association for Computing Machinery. https://doi.org/10.1145/3539813.3545124

Sun, A. (2023). Take a fresh look at recommender systems from an evaluation standpoint. In Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR ’23) (pp. 2629–2638). Association for Computing Machinery. https://doi.org/10.1145/3539618.3591931

Sysko-Romańczuk, S., Zaborek, P., Wróblewska, A., Dąbrowski, J., & Tkachuk, S. (2022). Data modalities, consumer attributes and recommendation performance in the fashion industry. Electronic Markets. https://doi.org/10.1007/s12525-022-00579-3

Referencias

Sysko-Romańczuk, S., Zaborek, P., Wróblewska, A., Dąbrowski, J., & Tkachuk, S. (2022). Data modalities, consumer attributes and recommendation performance in the fashion industry. Electronic Markets. https://doi.org/10.1007/s12525-022-00579-3

The New York Times. (2025). Books - The New York Times Best Sellers. Obtenido el 2 de noviembre de 2025, de https://www.nytimes.com/books/best-sellers/

ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

Take a Fresh Look at Recommender Systems from an Evaluation Standpoint

Aixin Sun, 2023

IIC3633 Sistemas Recomendadores 2025-2

Grupo 10

Nicolás Bueno | Felipe Fuentes | Cristóbal Saravia

Anexos

Las **métricas más utilizadas** para evaluar los sistemas de recomendación incluyen:

- Precision / Recall: qué proporción de recomendaciones fueron relevantes.
- Hit Rate: porcentaje de veces que el ítem correcto aparece entre los recomendados.
- NDCG (Normalized Discounted Cumulative Gain): mide la calidad del ranking, dando más peso a los ítems relevantes en posiciones altas.
- MAP (Mean Average Precision) y AUC (Area Under Curve): resumen la capacidad predictiva global del modelo.

Anexos

En su evaluación offline, los datos se dividen en conjuntos de entrenamiento y prueba (train/test split), usando distintos **enfoques de partición temporal**:

- Random Split: divide aleatoriamente las interacciones sin respetar el orden temporal.
- Leave-One-Out: usa la última interacción de cada usuario como prueba y el resto como entrenamiento.
- Sliding Windows: evalúa el modelo por ventanas de tiempo (por ejemplo, cada semana o mes), manteniendo la secuencia cronológica.
- Single Time Point Split: selecciona un punto específico en el tiempo; todas las interacciones anteriores se usan para entrenar y las posteriores para probar, respetando parcialmente la línea temporal.
- Simulation-Based Online: simula un entorno online donde las interacciones se procesan secuencialmente, evaluando el modelo de manera incremental conforme llegan nuevos datos.

Anexos

Single Time Point Split

Este método divide los datos en función de un punto fijo en el tiempo.

- Todas las interacciones antes de esa fecha se usan para entrenar el modelo.
- Todas las interacciones después se usan para evaluar.

Es más realista que random split o leave-one-out porque respeta la secuencia temporal, evitando que el modelo vea datos “del futuro”. Sin embargo, solo evalúa el desempeño en un único momento del tiempo, por lo que no refleja cómo cambia el sistema o las preferencias de los usuarios a lo largo del tiempo.

Simulation-Based Online

Este enfoque intenta simular el comportamiento de un sistema de recomendación real

- El modelo se actualiza dinámicamente conforme los usuarios interactúan, igual que en un entorno online.
- Permite probar estrategias adaptativas, por ejemplo, algoritmos de reinforcement learning o de aprendizaje incremental.

Es el método más cercano a la realidad, ya que reproduce el ciclo completo de recomendación → feedback → actualización, pero también es el más complejo y costoso de implementar en entornos de investigación.

Anexos

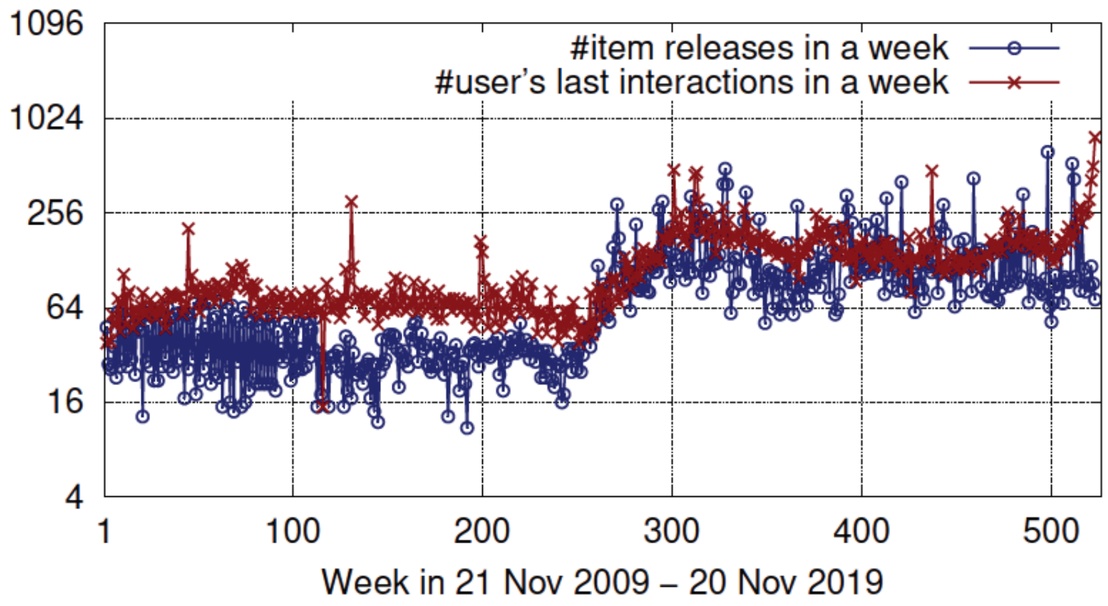

Figure 4: Number users whose last interaction occurred, and the number of movies which receives its very first rating (*i.e.*, item release) in each week, in the 10 years (or 520 weeks) period of the MovieLens-25 dataset (reproduced from [19]).

Anexos

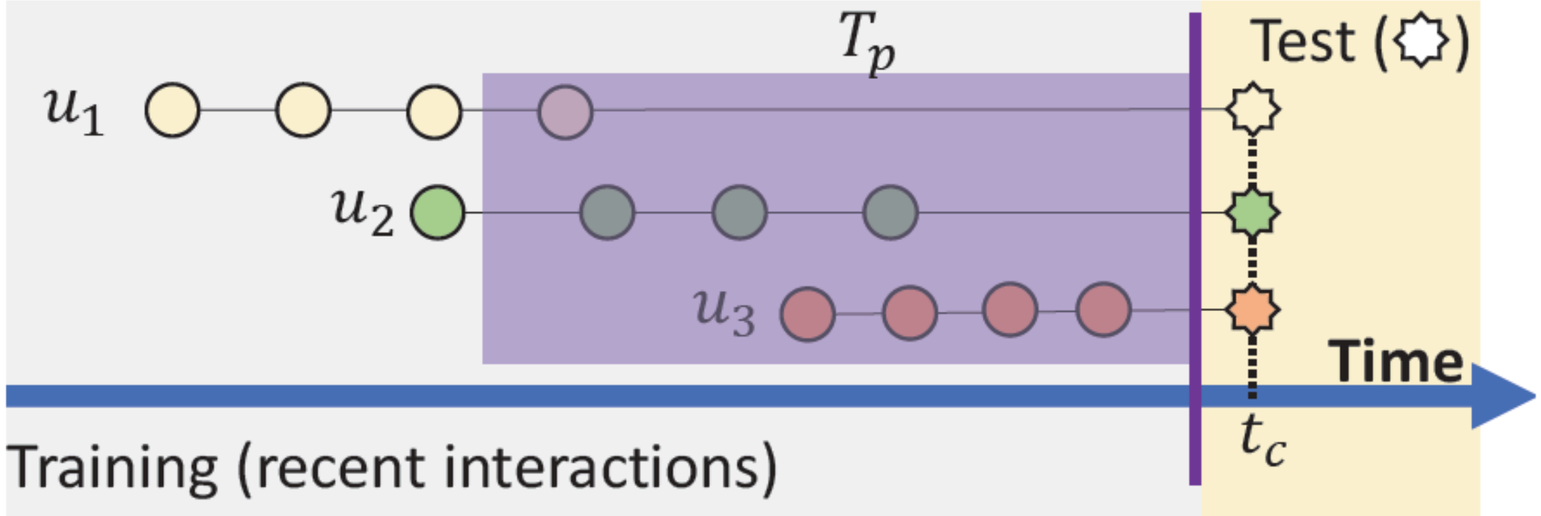

Figure 6: Illustration of evaluation of (recent) popularity along timeline. The popularity of an item is derived based on the interactions received in time duration T_p.