Post Processing Recommender Systems with Knowledge Graphs for Recency, Popularity, and Diversity of Explanations

Grupo 3: Felipe Marin, Camila Rojas y Matías Giddings

Contenidos

1. Contexto
2. Contribuciones
3. Marco Teórico y Estado del Arte
4. Detalles de la Solución
5. Resultados
6. Referencias

01

Contexto

Explicabilidad en los Sistemas Recomendadores

Explicabilidad

Explicar “Por qué” ciertos resultados son mostrados se ha vuelto una propiedad esencial en los sistemas de recomendación actuales. Por una parte, la regulación de **GDPR** (european General Data protection Regulation) hace un llamado a la explicabilidad.

Algunos modelos de recomendación existentes funcionan como cajas negras, las cuales no ofrecen justificación por las recomendaciones.

Los usuarios agradecen saber porque se les recomienda el contenido que se les muestra.

02

Contribuciones

Cómo podemos mejorar la explicabilidad

2.1. Propiedades

Recencia

Popularidad

Diversidad

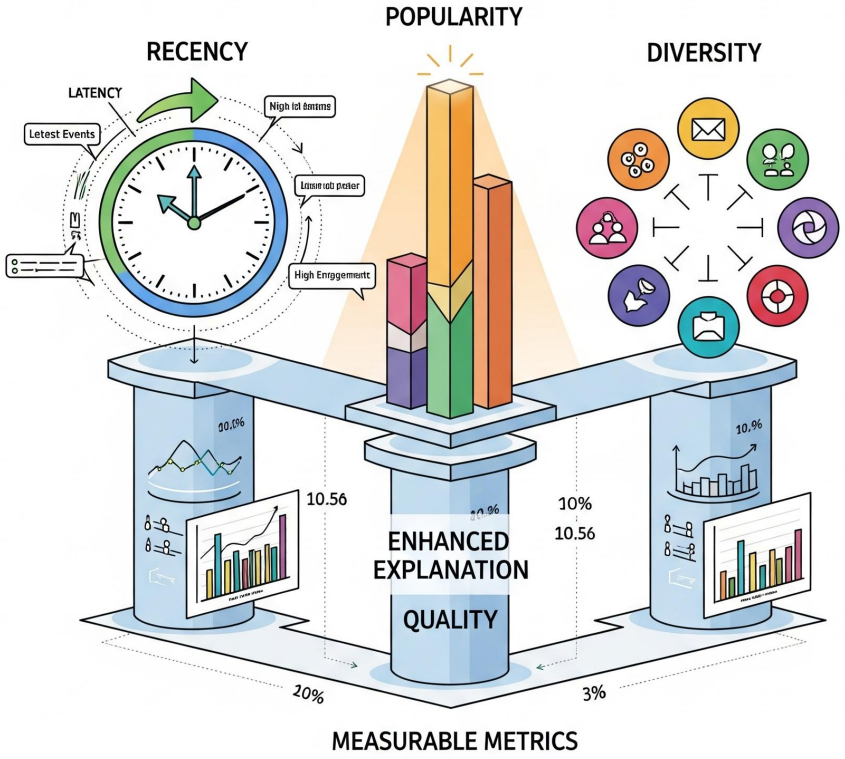

2.2. Métricas

Linking interaction Recency

Shared Entity Popularity

Explanation Type Diversity

2.3. Reordenamiento

- Reordenar las listas de recomendación
- Reordenar los caminos de explicación
- Optimizar las métricas propuestas

3. Estado del arte

Enfoques basados en regularización

Extienden la función objetivo para codificar relaciones de orden superior del KG. Estos enfoques usan conocimiento externo, pero sólo proporcionan interpretabilidad del modelo y **no generan explicaciones textuales para el usuario final**.

Enfoques basados en caminos (Path-based)

Se basan en caminos pre-calculados que modelan relaciones de orden superior entre usuarios y productos según la estructura del KG. Estos caminos pueden traducirse en explicaciones textuales, pero **no necesariamente reflejan cómo el usuario percibe o valora esa explicación.**

Existe una urgencia en los RSs explicables por mejorar la calidad percibida de las explicaciones desde la perspectiva del usuario

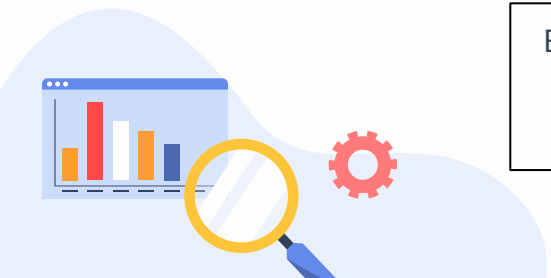

3. Marco teórico

Recencia de la Interacción Vinculante (LIR)

Antigüedad de la interacción pasada que se adjunta al camino de la explicación. Las interacciones más recientes se perciben como más fáciles de recordar y más conectadas a los gustos recientes del usuario.

Popularidad de la Entidad Compartida (SEP)

Las entidades populares pueden facilitar la comprensión de la explicación por parte del usuario (familiaridad), mientras que las entidades de nicho podrían ayudar a aprender nuevos vínculos (novedad)

Diversidad del Tipo de Explicación (ETD)

Una mayor diversidad de tipos de explicación puede mejorar la comprensión humana y contrarrestar el protagonismo de explicaciones genéricas.

1. **Grafo de Conocimiento (*G*):** Conjunto estructurado de tripletas que representan relaciones entre entidades. Incluye usuarios, productos y otras entidades del dominio.
2. **Camino (*l*):** Secuencia alternada de entidades y relaciones que conecta un usuario con un producto dentro del grafo. Se ocupa PGRP para la construcción de caminos. Cada camino constituye una posible explicación del vínculo entre entidad. Por ejemplo, usuario - vió → película - dirigida por → director - dirigió → otra película
3. **Tipo de Camino:** El tipo de camino depende de la última relación incluida en el patrón del camino. Refleja la naturaleza de la conexión explicativa.

$$G = \{(e_h, r, e_t)\}, \quad E = \text{conjunto de entidades}, \; R = \text{conjunto de relaciones}$$
$$l = \{e_1, r_1, e_2, \ldots, r_n, e_{n+1}\}$$
$$\omega_l = r_{|\pi_l|}, \quad \pi_l = \{r_1 \circ r_2 \circ \cdots \circ r_{|\pi_l|}\}$$

Objetivo de explicabilidad

- El modelo propuesto busca maximizar la expectativa de una función que combina la **utilidad de la recomendación** con la **calidad de las explicaciones** ofrecidas al usuario.
- Dado que la optimización conjunta es difícil, se propone maximizar las propiedades de explicación mediante métodos de re-ranking que actúan sobre las listas recomendadas y los caminos explicables.

$$\tilde{R} = \arg\max_{R} \mathbb{E}_{u \in U} \left[C_{RU}(u) + \sum_{C \in C_{EX}} C(u) \right]$$

Donde la utilidad de las recomendaciones proporcionadas por el modelo para el usuario u se define como la función $CRU : U \rightarrow R$.

4. Detalle de la Solución

Fase 1

Diseño de las propiedades de explicación. El proceso se separa en tres etapas: conceptualización, validación y operacionalización.

Fase 2

Incorporación de las propiedades de explicación en los modelos de recomendación a través de dos métodos.

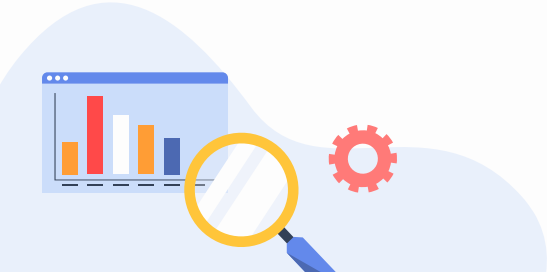

Fase 1: Conceptualización (Offline)

Basándose en la literatura de RS y psicología, se identificaron tres propiedades claves:

1. **Recencia**
2. **Popularidad**
3. **Diversidad**

Fase 1: Validación (Online)

Se realizó un cuestionario a 104 personas para confirmar la validez de las propiedades.

1. **Recencia**
   El 64.6% de los usuarios prefiere explicaciones basadas en interacciones recientes.
2. **Popularidad**
   El 63.3% considera relevante la popularidad de la entidad compartida.
3. **Diversidad**
   El 70% prefiere recomendaciones con explicaciones diversas.

Fase 1: Operacionalización

Se convirtieron las ideas en metricas medibles:

1. **Recencia → Linking Interaction Recency (LIR)**

$$LIR(p^i, t^i) = (1 - \beta_{LIR}) \cdot LIR(p^{i-1}, t^{i-1}) + \beta_{LIR} \cdot t^i$$

2. **Popularidad → Shared Entity Popularity (SEP)**

$$SEP(e^i, v^i) = (1 - \beta_{SEP}) \cdot SEP(e^{i-1}, v^{i-1}) + \beta_{SEP} \cdot v^i$$

3. **Diversidad → Explanation Type Diversity (ETD)**

$$ETD(\tilde{L}_u) = \frac{|\omega_{\hat{L}_u}|}{min(k, |\omega_L|)}$$

Fase 2: Optimización de las Propiedades

El núcleo de la solución es un **enfoque de re-ranking (reordenamiento)**, que es una estrategia de post-procesamiento. Esto significa que toman la lista de recomendaciones y las rutas de explicación de un modelo existente (como PGPR) y se reordenan para optimizar las nuevas métricas.

Optimización Suave

Reordena solo las explicaciones para cada producto recomendado, pero no cambia el orden de los productos.

Optimización Ponderada

Reordena tanto los productos como sus explicaciones. Este es el **enfoque principal** del paper.

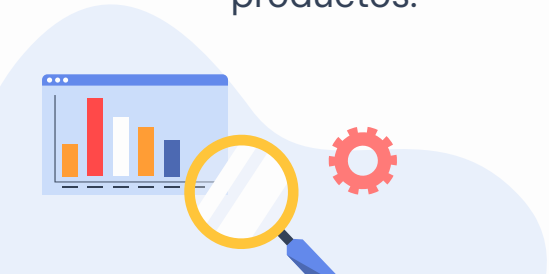

Fase 2: Detalle sobre Opt. Suave

El método de **Optimización Suave** Reordena solo las *explicaciones* para cada producto recomendado, pero no cambia el orden de los productos.

$$\hat{l}^{i}_{up} = \underset{l}{\operatorname{argmax}} \underset{l \in \tilde{L}_{up}}{\mathbb{E}} \sum_{C \in \mathbb{C}} C_{\tilde{P}^{i}_{u}}(u)$$

Fase 2: Detalle sobre Opt. Ponderada

El método de **Optimización Ponderada** utiliza un enfoque greedy basado en **Maximum Marginal Relevance (MMR)**. Para cada posición i en la lista de top-k, selecciona el siguiente producto p que maximiza una suma ponderada entre la utilidad de la recomendación y la calidad de la explicación:

$$\tilde{P}_u^i = \underset{\tilde{p} \in P - \tilde{P}_u^{i-1}}{\operatorname{argmax}} \; (1-\alpha) \sum_{p \in \{\tilde{p}\} \cup \tilde{P}_u^{i-1}} \tilde{R}_{up} + \alpha \max_{l \in \tilde{L}_{u\tilde{p}}} \sum_{C \in \mathbb{C}} C_{\tilde{P}_u^{i-1}}(u)$$

05

Resultados

Data Sets: MovieLens-1M y LastFM-1B

5.1. Re-ranking vs NDCG

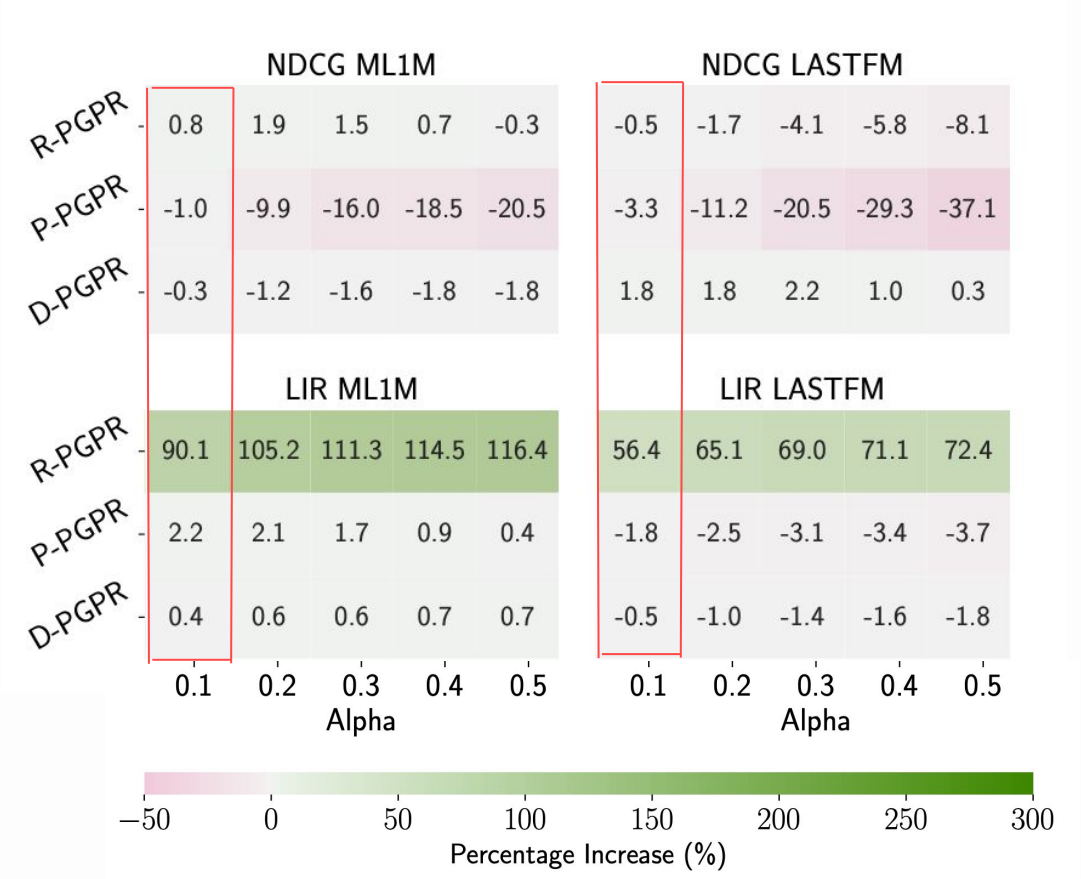

5.1. Re-ranking vs NDCG

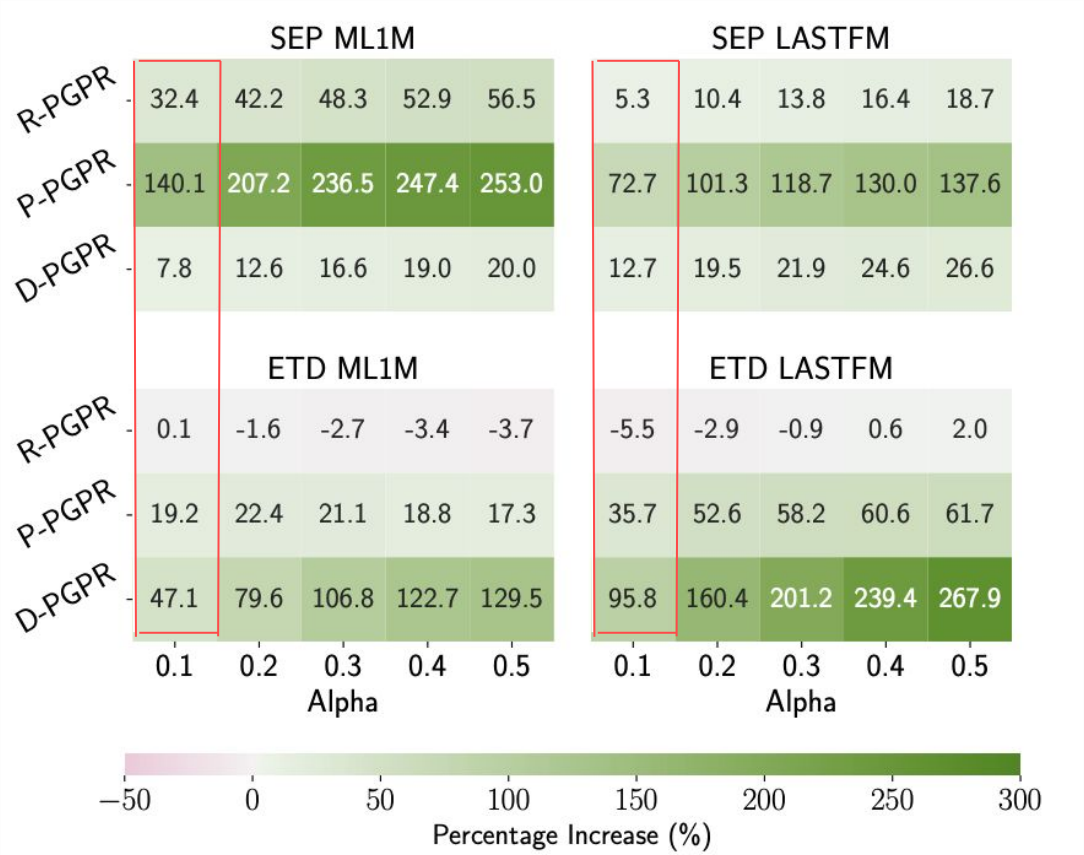

5.2. GDPR y re-ranking vs Otros modelos

Baseline ↑			Ours ↑		
Model	ML1M	LASTFM	Model	ML1M	LASTFM
FM	0.32	**0.15**	R-PGPR	**0.34**	<u>0.14</u>
BPR	<u>0.33</u>	0.13	P-PGPR	<u>0.33</u>	0.13
NMF	0.32	<u>0.14</u>	D-PGPR	0.32	<u>0.14</u>
CKE	<u>0.33</u>	<u>0.14</u>	DP-PGPR	0.31	0.13
CFKG	0.27	0.08	PR-PGPR	0.32	0.13
KGAT	<u>0.33</u>	**0.15**	DR-PGPR	0.32	0.13
PGPR	<u>0.33</u>	<u>0.14</u>	DPR-PGPR	0.31	0.13

For each dataset: best result in **bold**, second-best result <u>underlined</u>.

5.3. Modelos propuestos vs Métricas

	ML1M				LASTFM			
	EQ ↑	LIR ↑	SEP ↑	ETD ↑	EQ ↑	LIR ↑	SEP ↑	ETD ↑
PGPR	0.81	0.43	0.26	0.12	1.07	0.56	0.38	0.13
R-PGPR	1.37	**0.88**	0.37	0.12	1.50	**0.93**	0.43	0.14
P-PGPR	1.22	0.44	0.63	0.15	1.42	0.55	0.67	0.20
D-PGPR	1.05	0.43	0.33	**0.29**	1.50	0.55	0.47	**0.48**
DP-PGPR	1.37	0.44	**0.70**	0.22	1.56	0.55	0.68	0.32
PR-PGPR	**1.71**	0.86	**0.70**	0.14	1.80	0.86	0.50	0.43
DR-PGPR	1.59	0.84	0.46	**0.29**	**2.01**	0.86	**0.69**	0.46
DPR-PGPR	1.70	0.79	0.67	0.23	1.76	0.83	0.63	0.29

For each metric: best result in **bold**, second-best result underlined.

5.4. Modelo vs demografica

El modelo mejora/empeora la desigualdad en términos de utilidad de recomendación

En general la desigualdad en la utilidad de las recomendaciones para el modelo original no es impactada estadísticamente por nuestro enfoque

06

Referencias

Referencias importantes

Wang, S., Ren, Y., & Li, L. (2022). *Post-processing recommender systems with knowledge graphs for recency, popularity, and diversity of explanations.* In **Proceedings of the 4th Workshop on Graph-Based Recommender Systems (GRecSys'22)**, co-located with the 16th ACM Conference on Recommender Systems (RecSys 2022). CEUR Workshop Proceedings, Vol. 3177, 1–10. https://ceur-ws.org/Vol-3177/paper18.pdf

Qingyao Ai, Vahid Azizi, Xu Chen, and Yongfeng Zhang. 2018. *Learning Heterogeneous Knowledge Base Embeddings for Explainable Recommendation.* **Algorithms, 11(9)**, 137. https://doi.org/10.3390/a11090137

Zuohui Fu, Yikun Xian, Ruoyuan Gao, Jieyu Zhao, Qiaoying Huang, Yingqiang Ge, Shuyuan Xu, Shijie Geng, Chirag Shah, Yongfeng Zhang, and Gerard de Melo. 2020. *Fairness-Aware Explainable Recommendation over Knowledge Graphs.* In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2020), Virtual Event, China, July 25–30, 2020* (pp. 69–78). ACM. https://doi.org/10.1145/3397271.3401051

Yikun Xian, Zuohui Fu, S. Muthukrishnan, Gerard de Melo, and Yongfeng Zhang. 2019. *Reinforcement Knowledge Graph Reasoning for Explainable Recommendation.* In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2019), Paris, France, July 21–25, 2019* (pp. 285–294). ACM. https://doi.org/10.1145/3331184.3331203

Post Processing Recommender Systems with Knowledge Graphs for Recency, Popularity, and Diversity of Explanations

Grupo 3: Felipe Marin, Camila Rojas y Matías Giddings

Anexo

Table 1: Core notation adopted in our study.

Symbol	Description
U	The set of user entities
P	The set of product entities
R	The user-product relevance matrix
$\tilde{R}_{up}$	The predicted user-product relevance score
$\tilde{P}_u$	The ordered list of recommended products
l	An alternated path of entities and relationships
π_l	The pattern of a path l, i.e., list of relationships
ω_l	The type of a path l, i.e., the last relationship in π
$\hat{l}_{up}$	The predicted path selected for the explanation
L_{up}	The user-product paths between user and product
$\tilde{L}_{up}$	The predicted paths between a user and a product
$\hat{L}_{up}$	Sorted list of selected paths for a recommended list
S_l	The probability the model took that path

Anexo

Table 5: The difference between male and female user groups in terms of average recommendation utility (NDCG) and explanation quality (LIR, SEP and ETD).

	ML1M				LASTFM			
	ΔNDCG ↓	ΔLIR ↓	ΔSEP ↓	ΔETD ↓	ΔNDCG ↓	ΔLIR ↓	ΔSEP ↓	ΔETD ↓
PGPR	0.034*	-0.011	0.015*	0.002	-0.001	-0.014*	0.019*	0.002*
R-PGPR	0.033*	-0.007	0.008	0.002	-0.002	-0.008*	0.025*	0.003*
P-PGPR	0.036*	-0.013*	-0.001	0.002	-0.001	-0.004	0.017*	0.001
D-PGPR	0.034*	-0.014*	0.006	-0.011*	0.009*	-0.010*	0.013*	-0.015*
DP-PGPR	0.048*	-0.011*	-0.014*	-0.010*	0.006*	-0.003	0.020*	-0.006*
PR-PGPR	0.034*	-0.006	-0.009	0.002	-0.003	-0.008*	0.020*	-0.004*
DR-PGPR	0.036*	-0.012*	0.002	-0.008*	0.006	-0.004*	0.022*	-0.010*
DPR-PGPR	0.041*	-0.006	-0.009*	-0.005	0.005	-0.006*	0.024*	-0.004

(*) Statistically significant difference under a non-parametric Kruskal-Wallis test, $p = 0.05$.

Anexo

Table 2: Statistics of pre-processed data sets in this study.

		ML1M	LASTFM
User-Product Information	# Users	6,040	15,773
	# Products	3,226	47,981
	# Interactions	1,000,209	3,955,598
Knowledge Graph	# Entities	16,899	114,255
	# Relations	1.830.766	8,501,868
	# Triplets	156,261	464,567
	# Relations Types	10	9