PTADisc

Un Dataset Cross-Course para Aprendizaje Personalizado en Escenarios Cold-Start

Integrantes:
Martín Errázuriz
Santiago Peirano
Pedro Pablo Velasco

Contexto: Aprendizaje Personalizado y Diagnóstico

Objetivo: Estimar la competencia latente del estudiante para personalizar su ruta de aprendizaje.

Tareas Clave:

1. **Diagnóstico Cognitivo:** Evalúa la competencia estática.
2. **Trazado de Conocimiento:** Modela la competencia dinámica.

Brecha: Estudios existentes limitados a un solo curso. Faltan modelos para análisis *cross-course*.

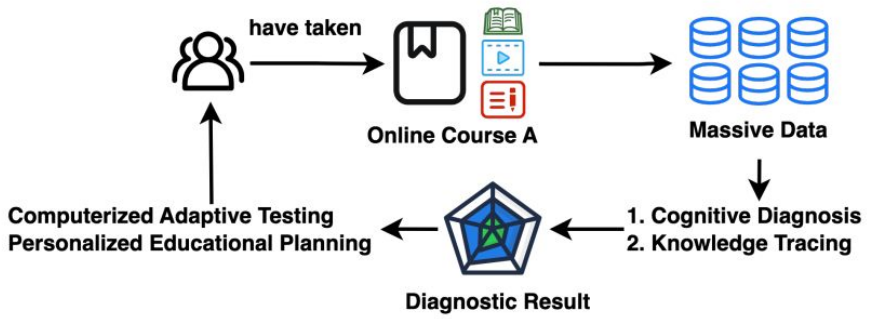

Contexto: El Problema del "Cold-Start"

- **Definición:** Ocurre cuando un estudiante se inscribe en un nuevo curso (Curso B).
- **Causa:** El estudiante tiene muy pocos o ningún registro (*response logs*) en este nuevo curso.
- **Consecuencia:** Es imposible para los modelos tradicionales (CD/KT) diagnosticar con precisión su competencia.
- **Hipótesis:** El rendimiento en cursos anteriores (Curso A) debería ayudar a informar su estado inicial en el Curso B.

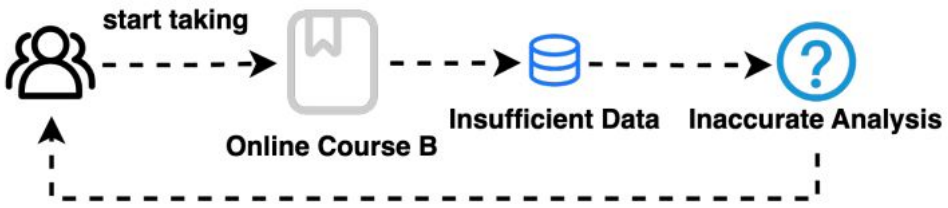

Problema de Recomendación: Cold-start Cross-Course

- **Perspectiva:** Transferir conocimiento del "Curso Fuente" al "Curso Target" para mejorar la personalización inicial.
- **Entradas:** Logs del curso fuente, Q-matrix de ambos cursos, y los logs del curso target.
- **Salidas:** Vector de competencia preciso en el target; predicciones de rendimiento correctas.
- **Objetivo:** Minimizar el error de predicción (RMSE, ACC, AUC) en el target, especialmente para estudiantes con datos escasos.

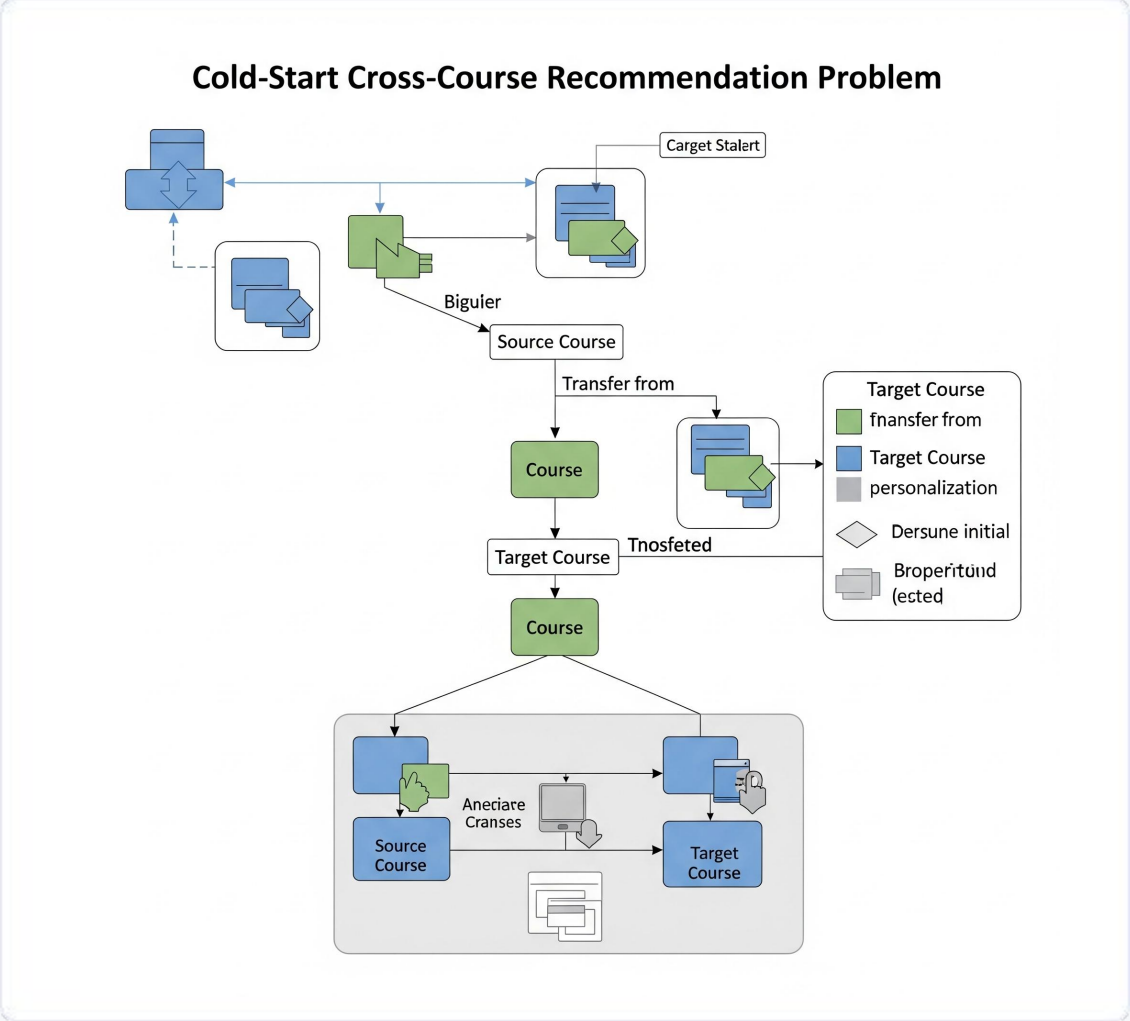

Contribución: PTADisc, un dataset masivo y diverso

Se construye y publica **PTADisc**, un dataset único del mundo real desde la plataforma "Programming Teaching Assistant (PTA)".

- **Inmenso:** 74 cursos, **1.53M** estudiantes, 225,615 problemas y más de **680 millones** de logs de respuestas.
- **Diverso:** Incluye logs de programación, grupos de estudiantes y dependencias de conceptos.
- **Centrado en Estudiante:** Organizado alrededor del comportamiento del estudiante.
- **Multi-Curso:** El primer dataset en incluir un subconjunto significativo (29,454 estudiantes) que cursan simultáneamente 5 cursos.

Contribución: CCLMF para cold-start cross-course

Se propone el **Cross-Course Learner Modeling Framework (CCLMF)**, un framework de meta-aprendizaje para el problema de cold-start.

- **Framework agnóstico al modelo:** Compatible con diversos modelos de diagnóstico (CD) y (KT).
- **Proceso en dos etapas:** (1) Pre-entrenamiento en curso fuente; (2) Meta-learning para generar mapeos.
- **Transferencia personalizada:** Genera una función de mapeo *única* para cada estudiante.
- **Mejoras cuantitativas:** Incrementos promedio de **+4.2% en AUC**, +5.5% en ACC y +5.3% en RMSE frente a modelos base.

Estado del Arte: Comparativa de Datasets

Table 5: Comparison between PTADisc and existing open datasets.

Field	Dataset Name	PTADisc	ASSIST	Junyi	KDD.	EdNet	MOOCCubeX	BePKT	CodeNet
Overview	Number of Logs	**6.81e8**	4.02e5	2.59e7	2.27e6	1.31e8	2.96e8	6.79e4	1.39e7
	Cross-course Info	✓	×	×	×	×	×	×	×
Concepts Variety	Concepts Annotations	✓	✓	✓	✓	✓	incomplete[5]	✓	×
	Concepts Dependencies	✓	×	✓	×	×	✓	×	×
Problems Variety	Programming Problems	✓	×	×	×	×	×	✓	✓
	Problem Type	✓	✓	✓	×	×	✓	×	×
Logs Variety	Detailed Programming Logs	✓	×	×	×	×	×	✓	✓
	Non-binary Response Results	✓	×	×	×	×	×	×	×
Other Info	Problem Set	✓	✓	×	✓	✓	✓	×	×
	Student Group	✓	✓	✓	×	×	×	×	×

Estado del Arte: Diagnóstico Cognitivo (CD)

Modelos Clásicos (Psicométricos):

- **IRT:** Modela la relación entre la capacidad latente (1D) y la probabilidad de acierto.
- **MIRT:** Extensión de IRT que modela múltiples dimensiones de habilidad.
- **DINA:** Evalúa la posesión de atributos (conceptos) requeridos.

Modelos de Aprendizaje Profundo:

- **NCD:** Utiliza redes neuronales para aprender interacciones complejas.
- **RCD:** Incorpora estructura relacional (grafos) entre conceptos.

Estado del Arte: Knowledge Tracing y Cross-Domain

- **Modelos Secuenciales de KT:** Se centran en el orden de las respuestas.
  Ejemplos: DKT (Recurrentes), DKVMN (Memoria), SAKT/AKT (Atención), GIKT/SGKT (Grafos).
- **Enfoques de Recomendación Cross-domain:** (No aplicados a CD/KT)
  Ejemplos: CMF (Factorización Colectiva), Mapeo/meta-learning (TMCDR, PTUPCDR).
- **Brecha Existente:** Ausencia de datasets y frameworks que conecten las competencias de estudiantes *entre* múltiples cursos.

Detalle Solución: Entidades del Dataset

El dataset se estructura en 4 entidades clave y 3 relaciones principales.

Entidades: Curso, Estudiante, Problema, Concepto.

Relaciones Principales:

1. Comportamiento (Logs): Estudiante <-> Problema
2. Correlación (Q-Matrix): Problema <-> Concepto
3. Dependencia: Concepto <-> Concepto

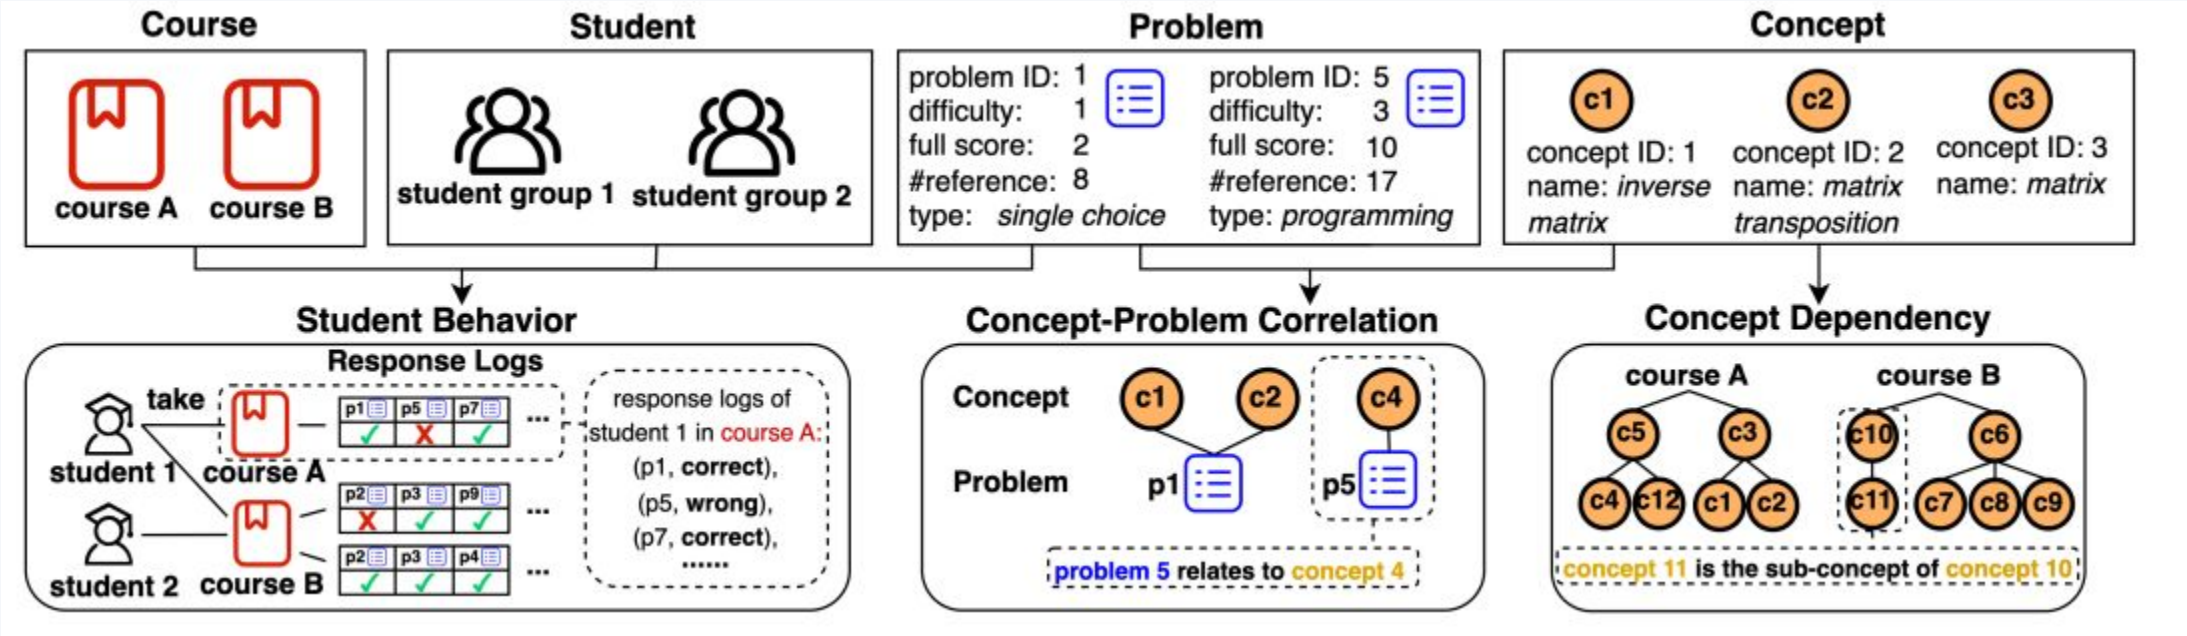

Detalle Solución: PTADisc – Pipeline de Construcción

El dataset final se construye mediante un riguroso pipeline de 6 pasos.

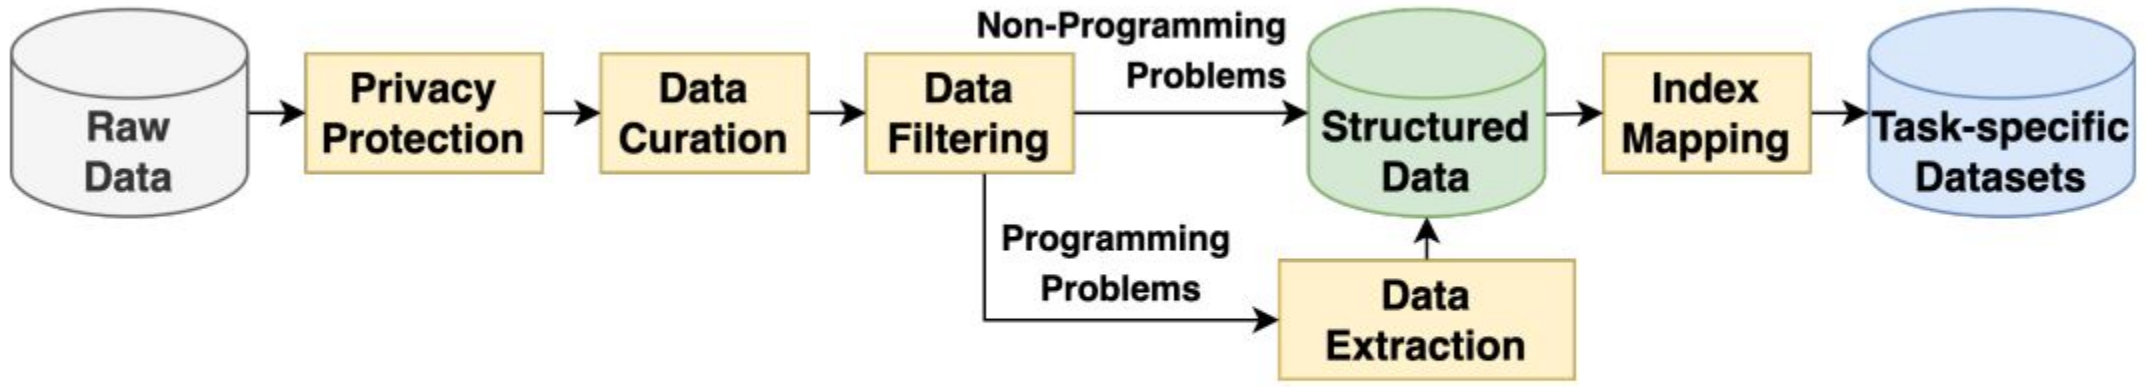

Figure 3: Construction pipeline of PTADisc.

Filtrado clave: Se seleccionaron 74 cursos manualmente. Se filtraron problemas sin anotación de conceptos y estudiantes con < 5 logs.

Detalle Solución: Arquitectura CCLMF

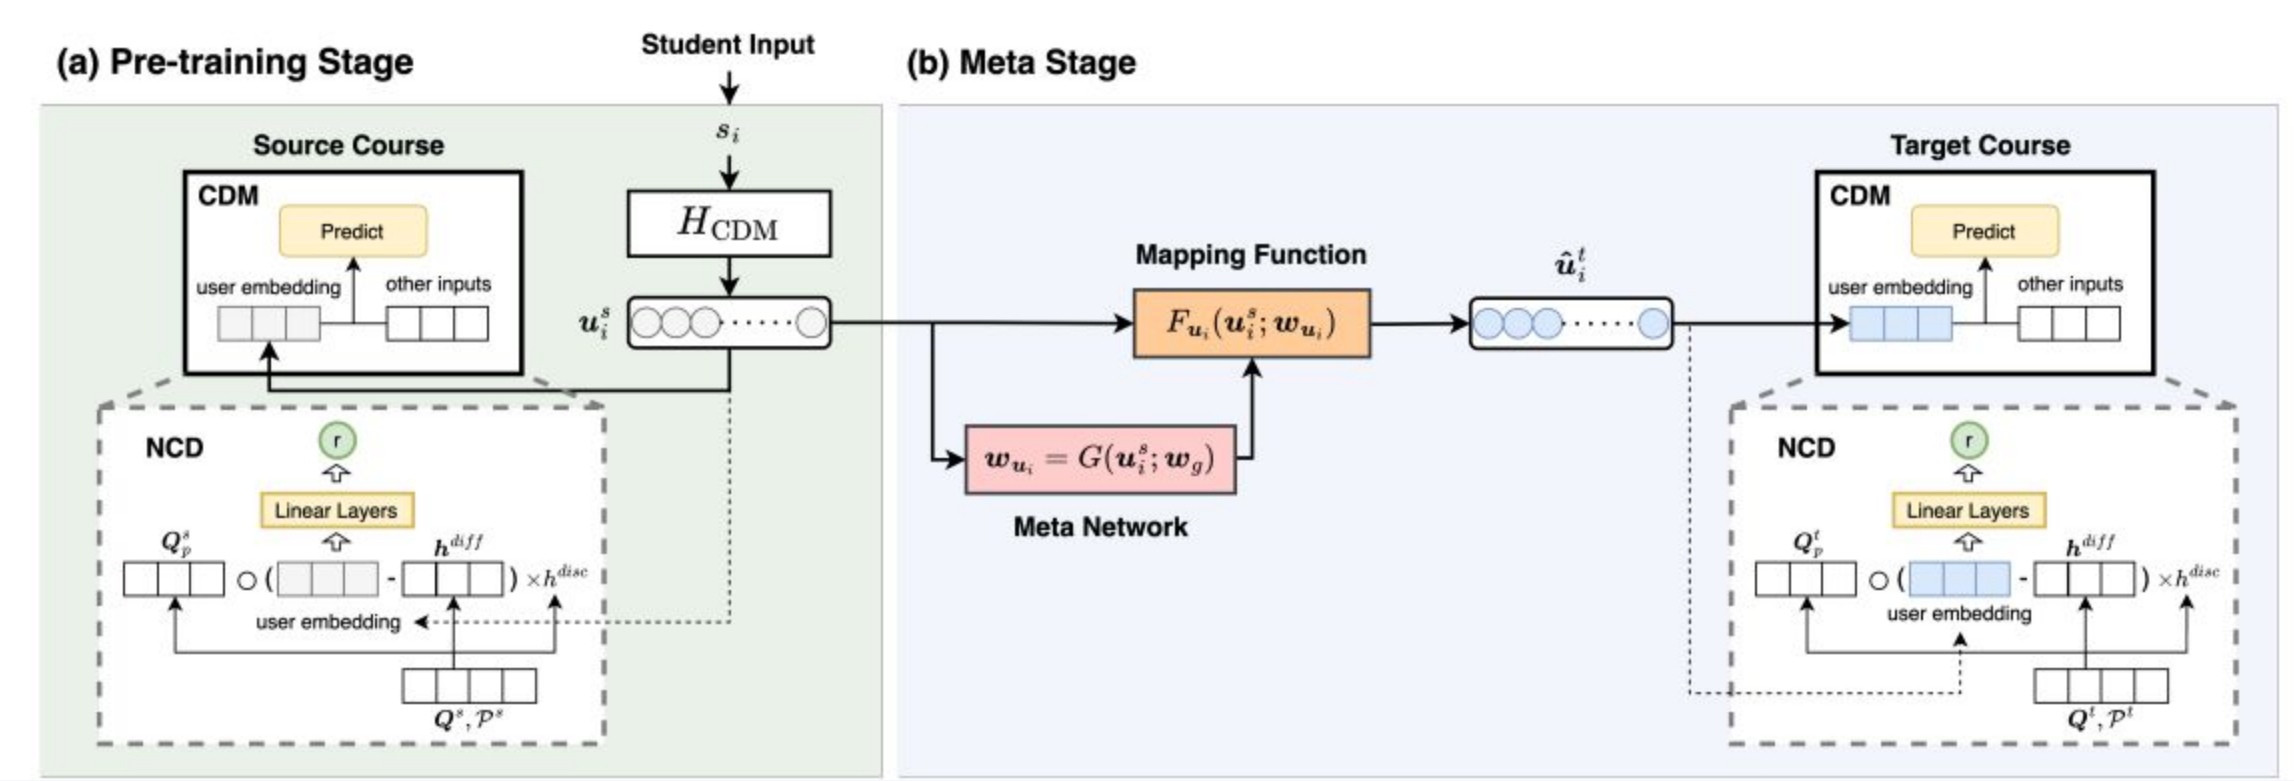

Detalle Solución: Ecuaciones Fundamentales

Ecuación 1: Representación de Aptitud Fuente

$$\boldsymbol{u}_i^s = H_{\mathrm{CDM}}(s_i; \boldsymbol{w}_h)$$

Se obtiene la aptitud u_i^s del estudiante i usando el modelo H_{CDM} entrenado en el curso fuente.

Ecuación 2: Generación de Parámetros de Mapeo (Meta-Red)

$$w_{u_i} = G(u_i^s; w_g)$$

La Meta-Red G toma la aptitud u_i^s y genera pesos w_{u_i} únicos para el mapeo de ese estudiante.

Detalle Solución: Ecuaciones Fundamentales

Ecuación 3: Mapeo de Aptitud al Curso Target

$$\hat{\boldsymbol{u}}_i^t = F_{\boldsymbol{u}_i}(\boldsymbol{u}_i^s; \boldsymbol{w}_{\boldsymbol{u}_i})$$

La función F_u (con sus pesos $\boldsymbol{w}_{\boldsymbol{u}_i}$) transforma la aptitud fuente $\boldsymbol{u}_i^s$ en la aptitud objetivo $\hat{\boldsymbol{u}}_i^t$.

Ecuación 4: Loss de Optimización (Task-Oriented)

$$loss_{\mathrm{CC-CDM}} = -\sum_i (r_i \log \hat{r}_i + (1 - r_i) \log (1 - \hat{r}_i)).$$

La Meta-Red se entrena optimizando la predicción $\hat{r}_i$ en el curso target (Loss de Cross-Entropy).

Detalle Solución: Resumen del Algoritmo

Algoritmo 1: CCLMF

Input: shared students: $\mathcal{S}$
other inputs: $\mathcal{P}^s, \mathcal{C}^s, \boldsymbol{Q}^s, \mathcal{R}^s, \mathcal{P}^t, \mathcal{C}^t, \boldsymbol{Q}^t, \mathcal{R}^t$

Pre-training Stage:

1. Train a CDM in the source course.
2. Get student proficiency representation in the source course: $\boldsymbol{u}_i^s = H_{\mathrm{CDM}}(s_i; \boldsymbol{w}_h)$.

Meta Stage:

1. Use a meta network $G(\cdot)$ to generate mapping function F_u.
2. Get the student proficiency representation in the target course by $\hat{\boldsymbol{u}}_i^t = F_{\boldsymbol{u}_i}(\boldsymbol{u}_i^s; \boldsymbol{w}_{\boldsymbol{u}_i})$.
3. Train $G(\cdot)$ and F_u by optimizing $loss_{\mathrm{CC-CDM}} = loss_{\mathrm{CDM}}(\hat{\boldsymbol{u}}_i^t, other_inputs)$.

Inference:

For a cold-start student s_j in the target course, his level of proficiency is $F_{\boldsymbol{u}_j}(\boldsymbol{u}_j^s; \boldsymbol{w}_{\boldsymbol{u}_j})$.

Evaluación: Setup Experimental

Dataset Cross-Course:

- 29,454 estudiantes que tomaron 5 cursos (Python, Java, C++, C, DS2).
- **Curso Fuente:** Python Programming.
- **Curso Target:** Java Programming.

Simulación Cold-Start:

- Se toma solo el 7% de los logs de Java como Target. Se crean 5 escenarios de escasez (dropout) del 10% al 50%.

Modelos y Métricas:

- **Modelos Base:** MIRT, NCD.
- **Modelos Propuestos:** CC-MIRT, CC-NCD.
- **Métricas:** AUC, ACC (Accuracy), RMSE.

Evaluación: Correlación de Desempeño

Hipótesis: Debe existir una correlación en el desempeño de los estudiantes entre los cursos.

Análisis:

- Fuerte correlación entre C y C++ (0.79).
- Correlación moderada/alta entre Python y Java (0.65).

Conclusión: La hipótesis se valida. Existe una base estadística sólida para la transferencia de conocimiento.

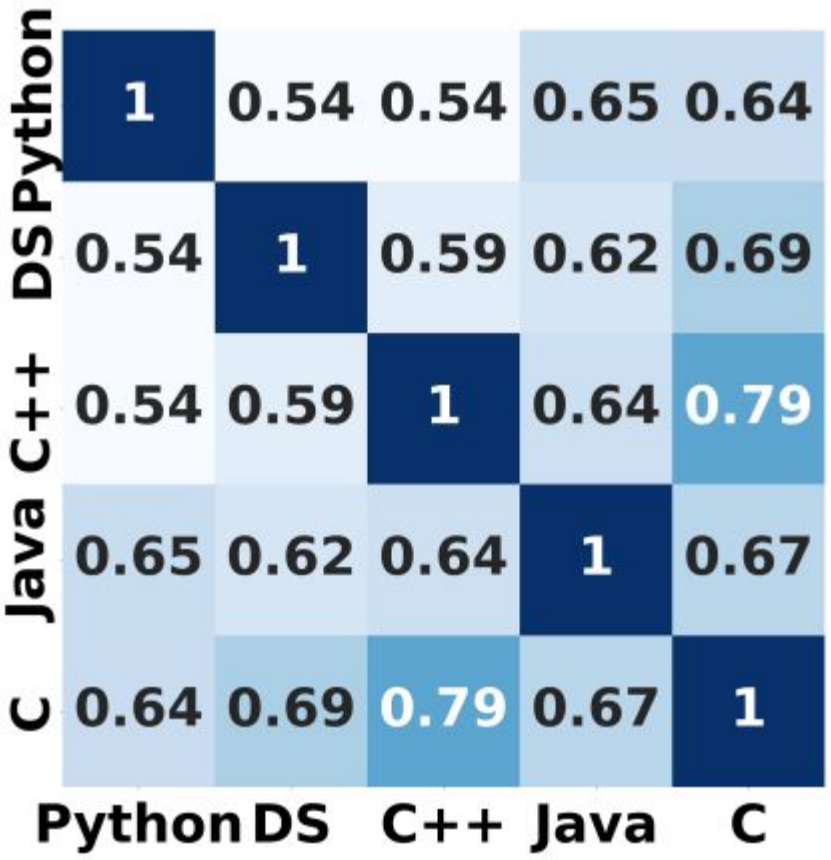

Evaluación: Distribución de Logs

Análisis:

- **Observación (Long-Tail):** Muestra una distribución de "larga cola". Pocos cursos tienen millones de logs, mientras que muchos tienen pocos.
- **Observación (Programación):** Los logs de programación (línea verde) son más escasos que los de no-programación (línea roja).

Esto valida la necesidad de un dataset grande, ya que la mayoría de los cursos tienen datos escasos individualmente.

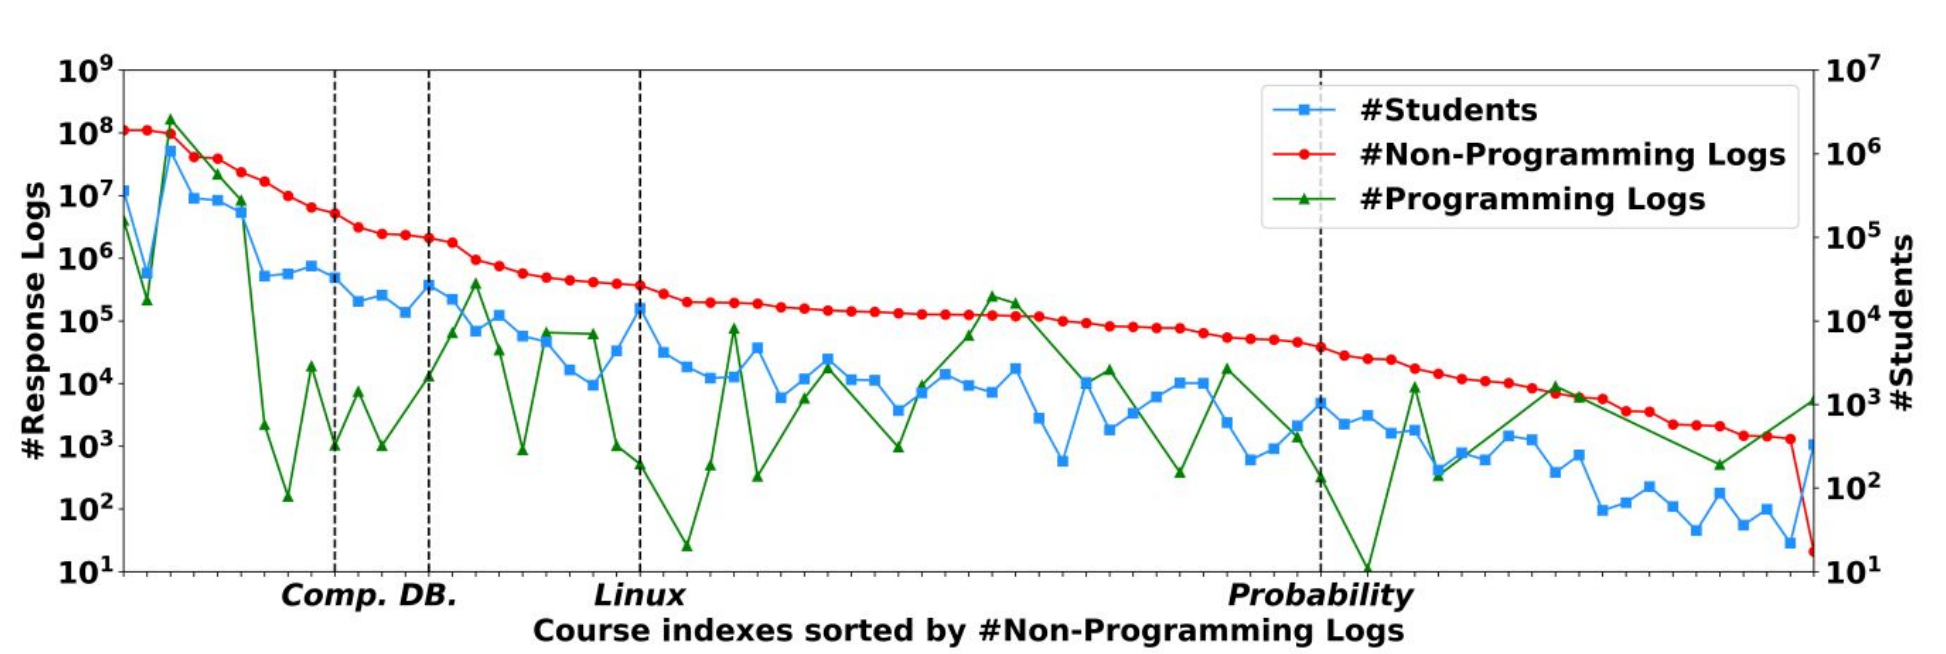

Evaluación: Resultados de CCLMF

Table 6: CCLMF results on MIRT and NCD.

Metrics	Model	no dropout	10% dropout	20% dropout	30% dropout	40% dropout	50% dropout
AUC	MIRT	0.6379	0.6412	0.6398	0.6399	0.6342	0.6363
	CC-MIRT	0.7059 (+0.0680)	0.7025 (+0.0612)	0.6998 (+0.0600)	0.6998 (+0.0599)	0.6957 (+0.0615)	0.6918 (+0.0555)
ACC	MIRT	0.6832	0.7037	0.6869	0.6886	0.6889	0.6991
	CC-MIRT	**0.7854 (+0.1022)**	0.7834 (+0.0797)	0.7826 (+0.0958)	0.7833 (+0.0947)	0.7822 (+0.0933)	0.7797 (+0.0806)
RMSE	MIRT	0.4902	0.4821	0.4884	0.4916	0.5013	0.4949
	CC-MIRT	0.3948 (-0.0954)	0.3965 (-0.0856)	0.3973 (-0.0911)	0.3973 (-0.0943)	0.3983 (-0.1029)	0.3999 (-0.0950)
AUC	NCD	0.6885	0.6846	0.6797	0.6787	0.6736	0.6675
	CC-NCD	0.7106 (+0.0221)	0.7061 (+0.0215)	0.7028 (+0.0231)	0.7007 (+0.0221)	0.6953 (+0.0216)	0.6895 (+0.0221)
ACC	NCD	0.7613	0.7662	0.7682	0.7606	0.7635	0.7640
	CC-NCD	0.7859 (+0.0246)	0.7834 (+0.0172)	0.7819 (+0.0137)	0.7814 (+0.0208)	0.7812 (+0.0177)	0.7817 (+0.0177)
RMSE	NCD	0.4109	0.4095	0.4081	0.4127	0.4121	0.4133
	CC-NCD	0.3966 (-0.0143)	0.3973 (-0.0122)	0.3981 (-0.0100)	0.3991 (-0.0136)	0.3998 (-0.0123)	0.4009 (-0.0124)

Evaluación: Análisis de Escasez

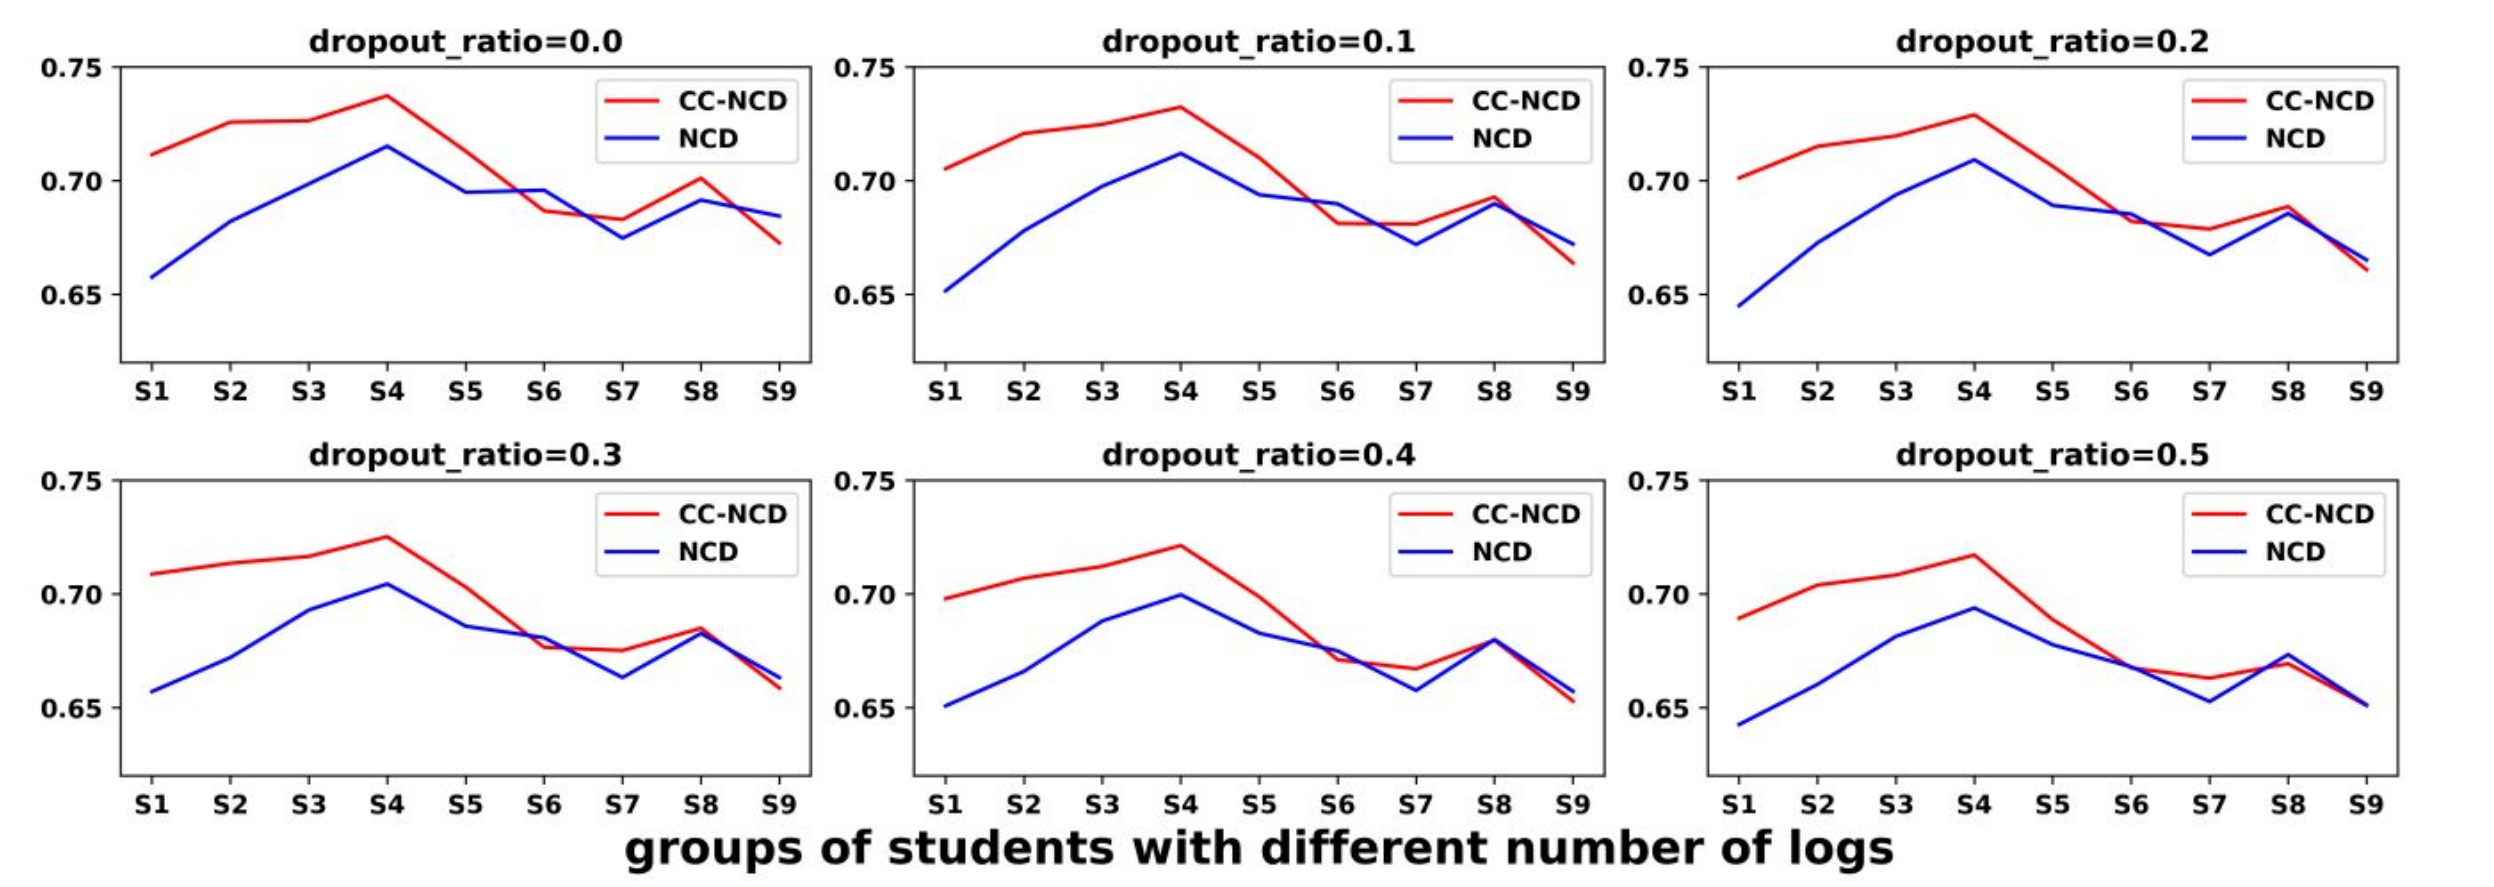

Evaluación: PTADisc como Benchmark

Table 8: Baselines of existing CD and KT models on PTADisc.

Dataset Name	Metric	DINA	IRT	MIRT	NCD	RCD	DKT	DKVMN	SAKT	AKT	GIKT	SGKT	PEBG
Probability	AUC	0.6569	0.7257	0.7324	0.7092	**0.7485**	0.6876	0.6815	0.6879	0.7123	0.7086	0.7079	**0.7320**
	ACC	0.6121	0.7097	0.7112	0.6894	**0.7196**	**0.7025**	0.6961	0.6721	0.6978	0.6883	0.6938	0.6977
	RMSE	0.5141	0.4490	0.4730	0.4590	**0.4346**	-	-	-	-	-	-	-
Linux	AUC	0.7577	0.8199	0.8168	0.8171	**0.8318**	0.7898	0.7856	0.7756	0.8074	0.8173	0.8156	**0.8379**
	ACC	0.7053	0.7802	0.7799	0.7755	**0.7860**	0.7726	0.7713	0.7665	0.7849	0.7791	0.7801	**0.8040**
	RMSE	0.4493	0.3900	0.4023	0.3934	**0.3841**	-	-	-	-	-		
DB	AUC	0.7141	0.7901	**0.8121**	0.7901	-	0.7813	0.7635	0.7562	0.7956	0.8101	0.7996	**0.8381**
	ACC	0.7856	0.8322	**0.8424**	0.8299	-	0.8312	0.8281	0.8181	**0.8383**	0.8353	0.8299	0.8373
	RMSE	0.3934	0.3493	**0.3407**	0.3504	-	-	-	-	-	-	-	-
Comp	AUC	0.7137	0.7819	**0.8096**	0.7734	-	0.7978	0.7811	0.7717	0.8091	0.8091	0.8172	**0.8281**
	ACC	0.7303	0.7929	**0.8018**	0.7880	-	0.8276	0.8234	0.8012	0.8283	**0.8337**	0.8274	0.8194
	RMSE	0.4335	0.3808	**0.3749**	0.3849	-	-	-	-	-	-	-	-

Conclusión y Trabajo Futuro

Conclusiones Clave:

- **PTADisc** es un nuevo dataset que permite estudios de transferencia cross-course en programación.
- **CCLMF** mitiga el "cold-start" usando meta-aprendizaje para mapeos *personalizados*.
- La transferencia personalizada supera a los modelos base en escenarios de alta escasez de datos.

Limitaciones y Trabajo Futuro:

- **Limitación:** El texto de los problemas no puede ser compartido (copyright).
- **Futuro:** Investigar aprendizaje adaptativo (CAT) y planificación educacional.
- **Futuro:** Explorar KT específico para programación, usando los logs de código.

Gracias

Referencias Clave (Selección)

Bi, H., et al. (2020). Quality meets diversity... In ICDM.

De La Torre, J. (2009). Dina model and parameter estimation...

Ghosh, A., et al. (2020). Context-aware attentive knowledge tracing. In SIGKDD. (AKT)

Liu, Y., et al. (2020). Improving knowledge tracing via pre-training... (PEBG)

Man, T., et al. (2017). Cross-domain recommendation... In IJCAI.

Piech, C., et al. (2015). Deep knowledge tracing. NIPS. (DKT)

Reckase, M. D. (2009). Multidimensional item response theory models... (MIRT)

Wang, F., et al. (2020). Neural cognitive diagnosis... In AAAI. (NCD)