Revealing the Hidden Impact of Top-N Metrics on Optimization in Recommender Systems

Lukas Wegmeth, Tobias Vente, Lennart Purucker

Grupo 16
Jorge De La Fuente, Jorge Jacque, Francisco Solís

13 de noviembre

Contexto - ¿Evaluar solo top-n sesga el tuning?

- En evaluación de RecSys, se suelen usar métricas **top-n**, que solo toman en cuenta los primeros k elementos de la lista.
- Muchas veces, esto **no** coincide con la función de pérdida que se usa para ajustar hiperparámetros al entrenar modelos.
- En ese sentido, el paper propone que evaluar solo el top-n, podría **no** reflejar la máxima exactitud posible[1]del modelo durante la optimización

[1]exactitud predictiva: medida por las métricas objetivo de optimización típicas

Contexto - ¿Evaluar solo top-n sesga el tuning?

Hay **dos** preguntas (RQs) que guían el trabajo:

1. ¿existen casos en que no elegir el top-n **mejora** la exactitud?
2. si es que sí, ¿ese efecto **tiene impacto real** en la optimización?

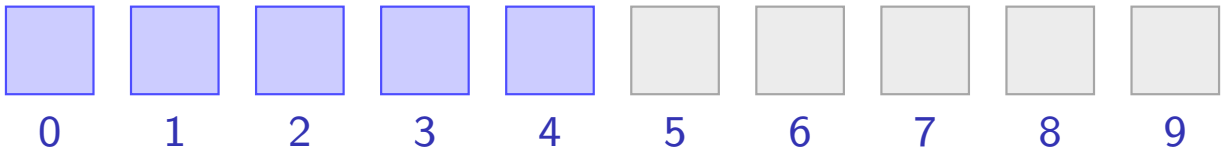

¿Y si incluir posiciones más abajo, como 5 a 9, mejorara realmente la métrica?

Problema de recomendación - Estrategia de selección

- Para cada usuario, el modelo entrega un ranking ordenado:

$$P = (i_0, i_1, \ldots, i_{K-1}).$$

- Queremos medir una métrica top-n (por ejemplo nDCG@5).
- Una **estrategia de selección** S es el conjunto de **posiciones** del ranking que vamos a usar para calcular la métrica.
- Por ejemplo, con $K = 10$ y $n = 5$:

$$S = \{0, 2, 3, 5, 7\}$$

es una estrategia alternativa al *top-5* clásico $\{0, 1, 2, 3, 4\}$.

Nota: S elige **posiciones**, no reordena el ranking.

Problema de recomendación - Estrategia de selección

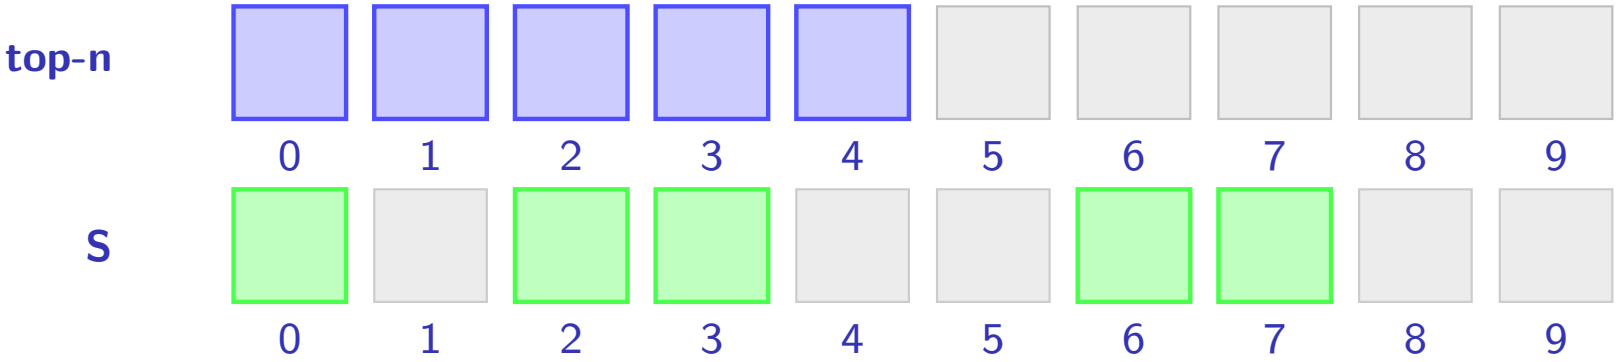

Mismo ranking de 10 ítems; dos formas distintas de elegir 5 posiciones.

Contribución: cuestiona, comprueba y confirma

- Presenta el **primer estudio a gran escala** que analiza el posible **impacto oculto** de las métricas top-n en la **optimización de hiperparámetros**.
- Demuestra que **sí existen casos** donde una estrategia **no-top-n** supera a **top-n** (**RQ1**).
- El efecto observado es **mínimo y estable**, por lo que su **impacto práctico** resulta **insignificante** (**RQ2**).
- Concluye que las métricas **top-n tradicionales** siguen siendo **fiables y adecuadas** para evaluar sistemas de filtrado colaborativo.

Contribución: cuestiona, comprueba y confirma

El trabajo no propone un nuevo método; ofrece **evidencia empírica** de que top-n sigue siendo fiable.

Marco teórico

- Tipos de feedback:
  - Implícito
  - Explícito
- Top-n
- Precision@N
- nDCG@N
- Optimización de hiperparámetros
- Función de pérdida
- Re-Ranking
- PRP: Probability Ranking Principle
- Friedman y Nemenyi

Estado del Arte

- Optimización de hiperparámetros
- Discrepancia entre las métricas de pérdida de entrenamiento y las métricas objetivo de optimización
- Re-ranking
- PRP

Requiere una métrica que refleje la verdadera capacidad predictiva del modelo o los resultados no serán los esperados.
La mayoría de estudios reportan resultados a partir de **hiperparámetros ya optimizados.**

Estado del Arte - Discrepancia entre las métricas de pérdida de entrenamiento y las métricas objetivo de optimización

- Modelos se entrenan con una función de pérdida.
- Luego se evalúan con métricas distintas.
- Esto genera una discrepancia en el análisis de los resultados.
- Para abordar este problema se diseñan nuevas métricas.
- Esta investigación no busca eso, sino que **analizar si tiene sentido evaluar siempre usando solo los ítems Top-N.**

Estado del Arte - Re-ranking

- Técnicas que reorden de los ítems que buscan alcanzar objetivos distintos al aumento de la presición predictiva
- En este estudio se propone **reordenar los ítems durante la optimización del modelo, para ver si eso mejora la precisión predictiva.**

- Este principio asume que un algoritmo de recomendación óptimo ordena los ítems según su probabilidad de relevancia para el usuario
- En contraste, este estudio **cuestiona si el top-N que genera el modelo es realmente el mejor conjunto posible.**

Detalle de la solución

- Este trabajo busca evaluar distintas estrategias de selección en la evaluación de sistemas de recomendación.
- **P**: Lista ordenada de ítems predicha por un sistema de recomendación
- **Estrategia de selección**: método para escoger cualquier combinación de n ítems de P, con $n \leq |P|$, para luego evaluar la precisión del sistema usando una métrica basada en umbral, como nDCG@n.

- **Diseño metodológico:** Sea $K \subseteq P$ los $|K|$ items con mayor puntuación predicha. En el estudio se fijaron los valores: $K = 10$ y $n = 5$ Lo que genera 252 posibles estrategias de selección.
- El objetivo central del trabajo es **determinar si existe alguna estrategia de selección no-top-n que produzca un valor de nDCG@n superior al obtenido con la estrategia tradicional top-n.**

Detalle de la solución - Datos

- Se analizan doce conjuntos de datos de retroalimentación implícita y ocho de retroalimentación explícita, provenientes de seis dominios diferentes, con nueve algoritmos de recomendación y dos baselines, implementados en las bibliotecas Implicit y LensKit.
- Objetivo: garantizar que los resultados fueran **robustos** y **generalizables** entre distintos contextos
- En los conjuntos de datos explícitos, se considera como interacción toda calificación superior al 60 % del valor máximo
- Se aplica un filtrado five-core, conservando solo usuarios e ítems con al menos 5 interacciones.

Detalle de la solución - Protocolo Experimental

- Se realizó una **validación cruzada de cinco pliegues**, dividiendo aleatoriamente las interacciones de cada usuario en tres conjuntos:
  - Entrenamiento (60%)
  - Validación (20%)
  - Prueba (20%)
- Recomendadores optimizados con **random search**, con rangos de **hiperparámetros similares a valores por defecto** de las bibliotecas.
- Se centraron en analizar resultados sobre el conjunto de prueba, pero también analizaron sobre el conjunto de evaluación.
- Recursos Computacionales: Cluster con 256 GB RAM por nodo, 64 cores y una CPU AMD EPYC 7452

Resultados

- **Resultados agregados**
- **Resultados usando subset de un dominio específico**
- **Resultados específicos para cada set de datos**

Resultados agregados

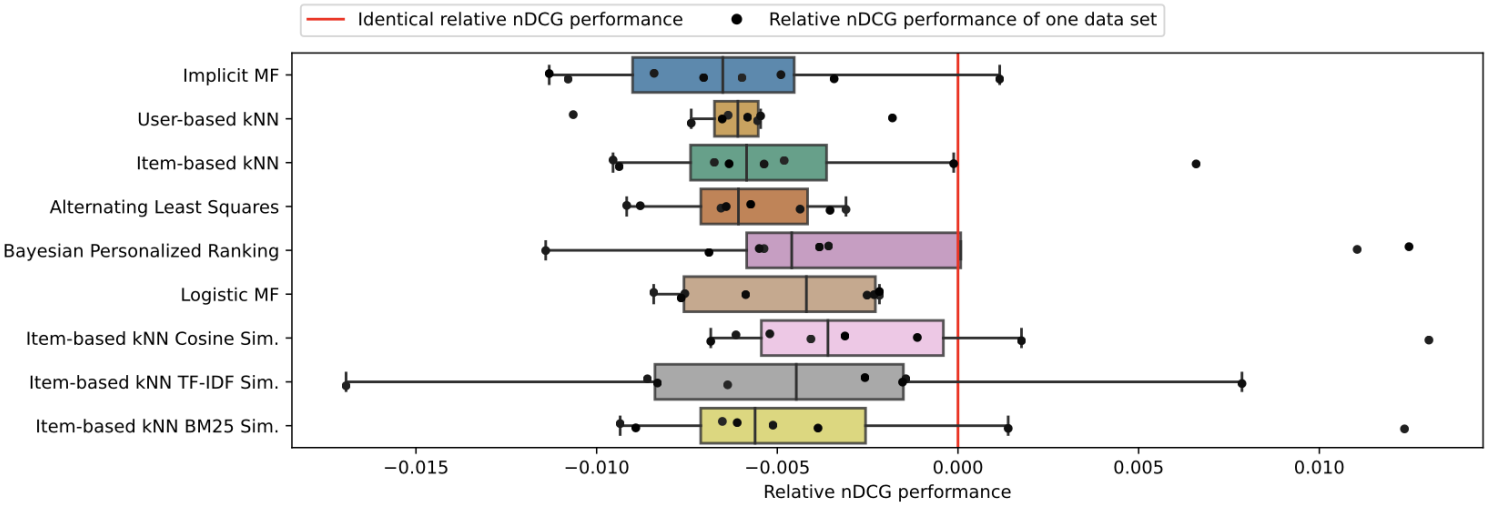

(c) Non-baseline algorithms for explicit feedback.

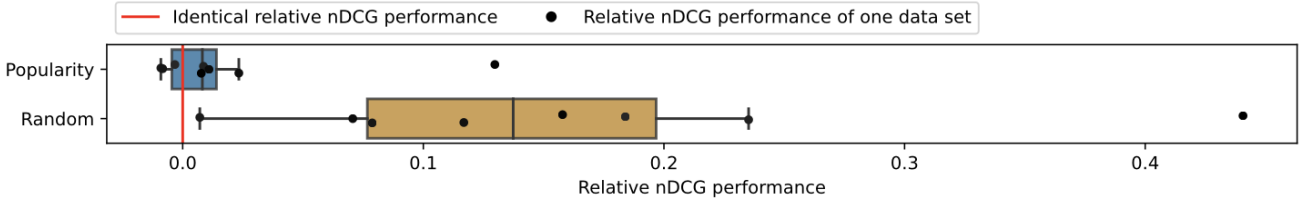

(d) Baseline algorithms for explicit feedback.

Figure: Resultados para feedback explícito

[2] Los resultados de feedback implícito en anexo

- Hay sets de datos en donde la estrategia top-n no es la mejor
- En promedio, top-n es la mejor estrategia
- Recomendar ítems basados en popularidad usando top-n es subóptimo.

Resultados por dominio específico

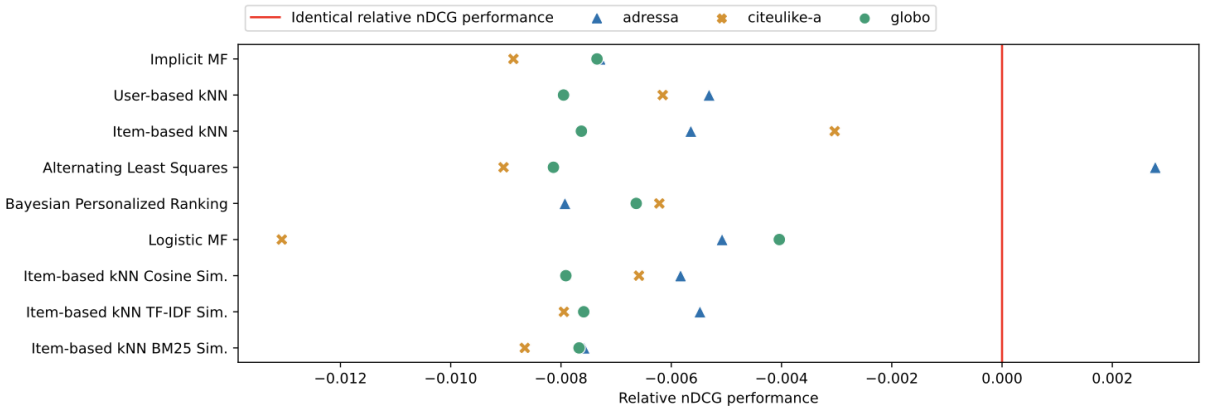

(a) *Articles* recommendation domain (3 data sets, implicit feedback).

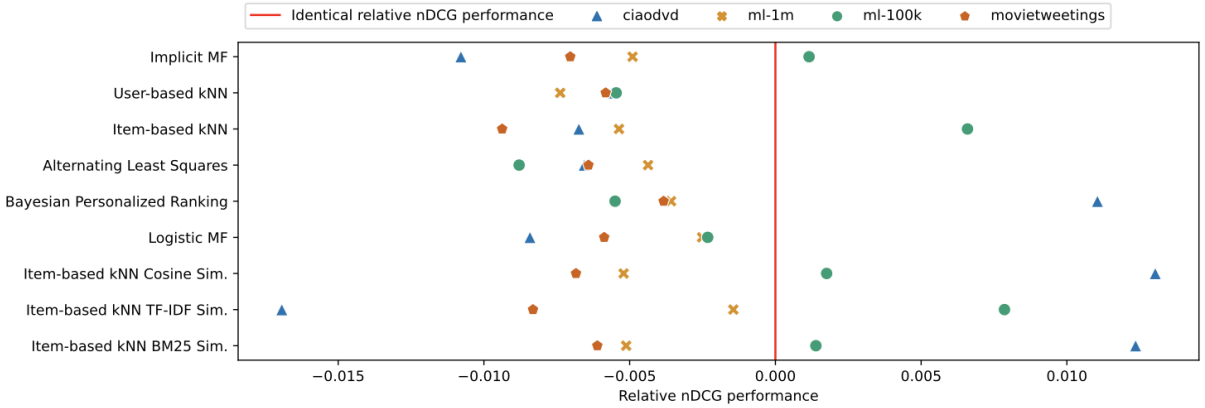

(b) *Movies* recommendation domain (4 data sets, explicit feedback).

Figure: Resultados por dominio específico para articulos y películas

- **El rendimiento relativo de la mejor estrategia de selección puede ser específica para un algoritmo o set de datos**

Resultados por dataset específico

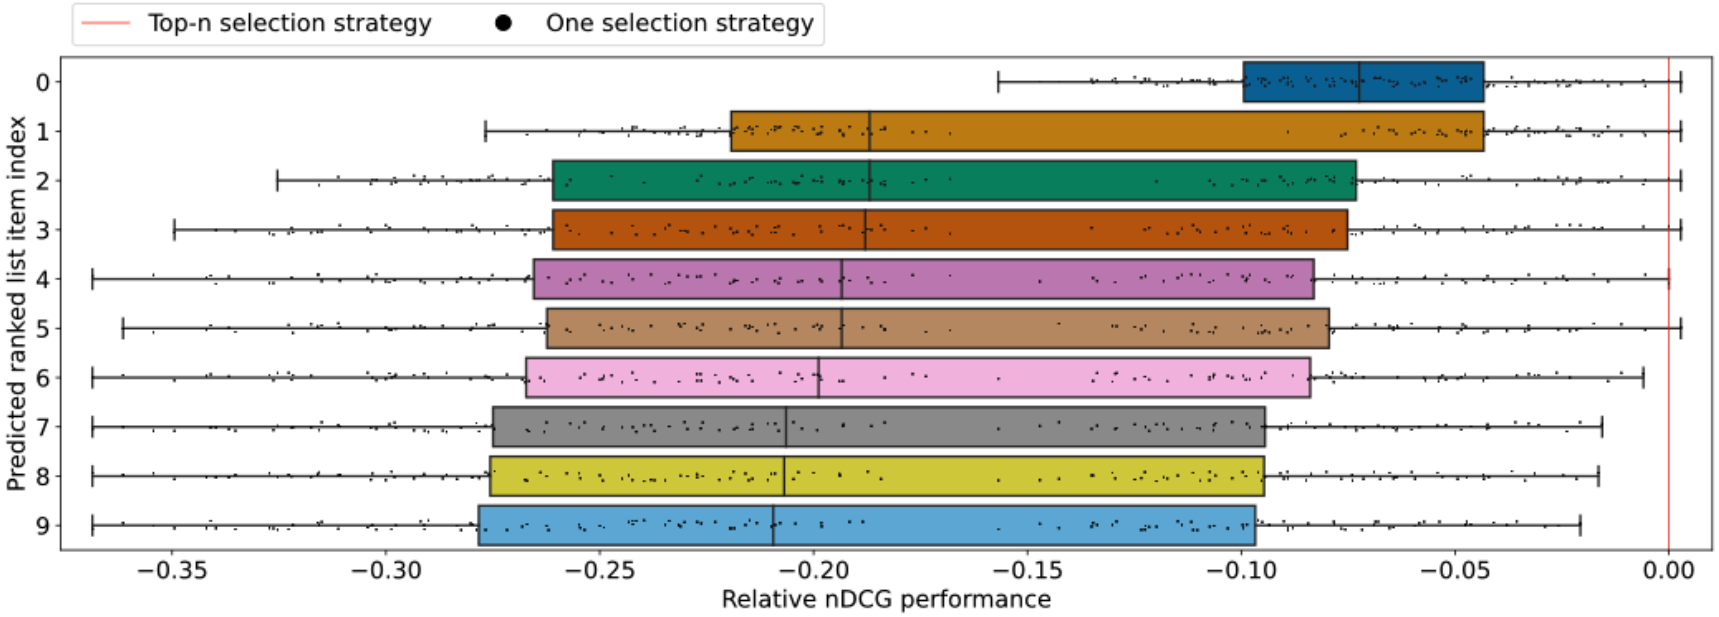

(a) *Adressa One Week* data set.

Figure: Resultados para dataset Adressa

- No hay garantías que tomar los 5 primeros ítems sea lo óptimo.
- No existe un patrón monótono perfecto, es decir, hay ítems que no pertenecen a los 5 primeros, pero pueden mejorar la métrica.

Generalización

¿Son las estrategias capaces de generalizar los resultados obtenidos del test set, al set de validación?

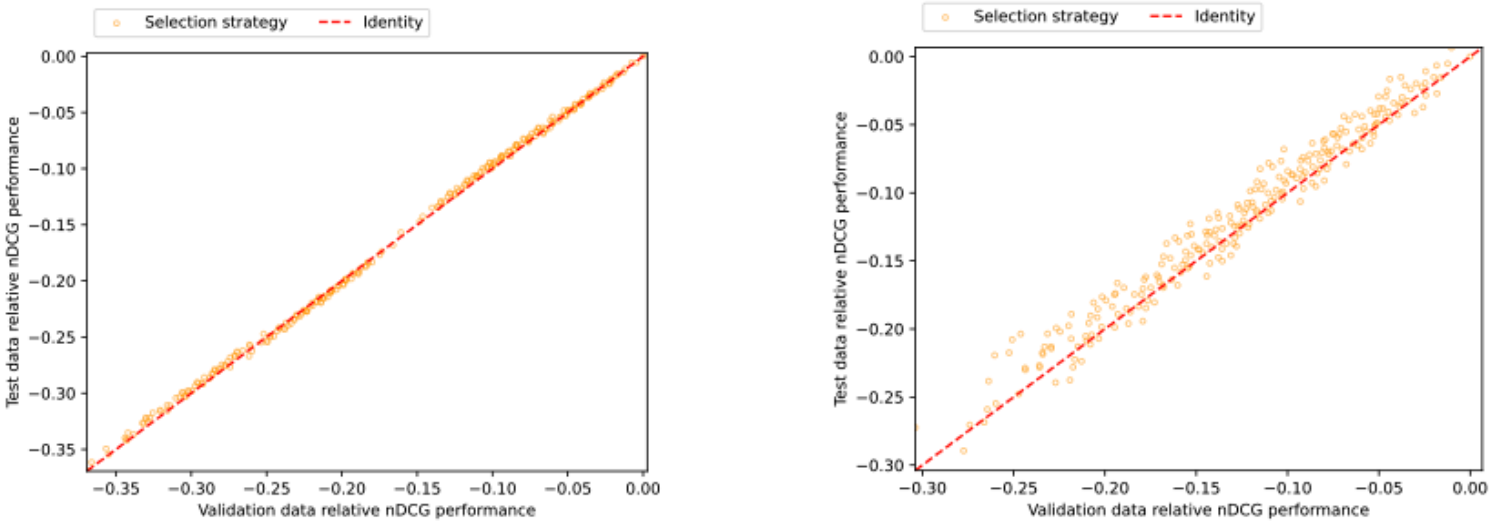

(a) *Adressa One Week* (b) *MovieLens-100k*

Fig. 4: The relative performance of *selection strategies* on the validation and test set for the data sets *Adressa One Week* (4a) and *MovieLens-100k* (4b). If a point is on the identity line, the validation and test set have equal relative performance and, therefore, generalize.

Figure: Correlación de Pearson para las distintas estrategias de selección

Conclusiones

- **(RQ1) ¿La selección de ítems distintos a los top-n durante la evaluación de sistemas de recomendación produce una mayor precisión predictiva para algoritmos, dominios o conjuntos de datos específicos?** Si, $\approx 0.01\%$ de las estrategias de selección no-top-n tuvieron mejor rendimiento que la estrategia top-n.

- **(RQ2) Si existen casos en los que seleccionar ítems distintos a los del top-n mejora la precisión predictiva, ¿Tienen las métricas top-n un impacto significativo en la optimización?** El impacto es insignificante. La ganancia máxima es marginal, 0.4% en los datasets de feedback implícito y menos de 1.5% en los datasets de feedback explícito.

Conclusiones

- La selección del top-n es la mejor en promedio.
- Buscar la mejor estrategia de selección en la práctica puede ser muy costoso.
- El impacto de las métricas del tipo top-n en la optimización de los sistemas recomendadores es insignificante. No hay beneficios en optimizar la estrategia de selección.
- Usando test de hipótesis (Friedman test + Nemenyi test), indican que $\approx 43\%$ de las mejores estrategias de selección, no difieren en rendimiento.
- Las estrategias de selección generalizan bien, por lo que es posible buscar la mejor estrategia en el set de validación y esperar que va a generalizar bien para el set de testeo.

Bibliografía

- Wegmeth, L., Vente, T., Purucker, L. (2024, March). Revealing the Hidden Impact of Top-N Metrics on Optimization in Recommender Systems. In European Conference on Information Retrieval (pp. 140-156). Cham: Springer Nature Switzerland.

Anexos
Resultados agregados feedback implícito

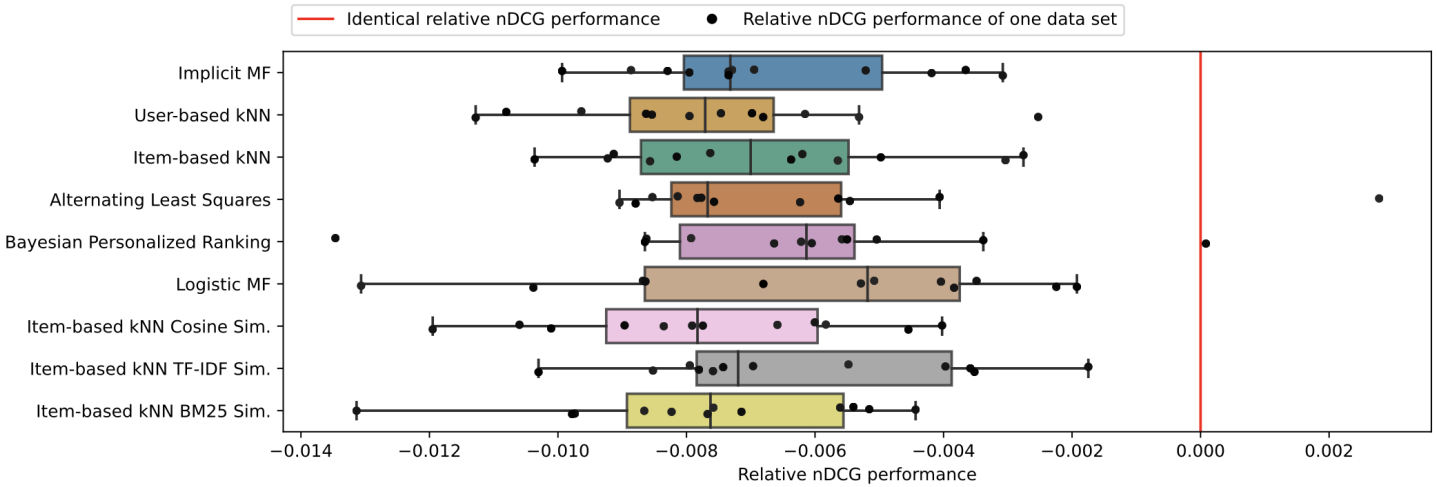

(a) Non-baseline algorithms for implicit feedback.

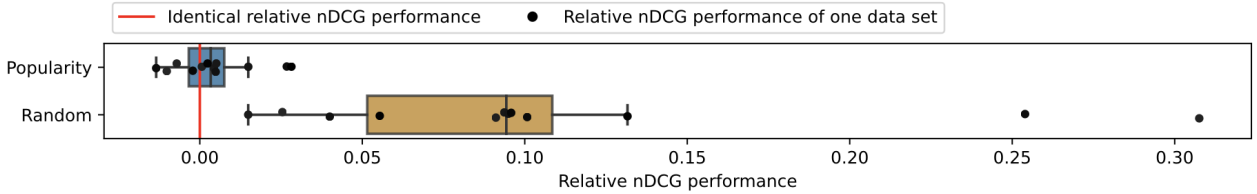

(b) Baseline algorithms for implicit feedback.

Figure: Resultados para feedback implícito

Anexos
Tabla coeficientes de Pearson

Table 2: The Pearson correlation coefficients of the performance of *selection strategies* of the validation set compared to the test set separated by implicit and explicit feedback sets. A Pearson correlation coefficient of one would mean that *selection strategies* perfectly generalize from validation to test.

Algorithm	Pearson Corr. Coeff. Implicit	Pearson Corr. Coeff. Explicit
Implicit MF	0.998	0.988
User-based kNN	0.999	0.990
Item-based kNN	0.998	0.994
Alternating Least Squares	0.999	0.986
Bayesian Personalized Ranking	0.995	0.966
Logistic MF	0.995	0.983
Item-based kNN Cosine Sim.	0.999	0.990
Item-based kNN TF-IDF Sim.	0.998	0.992
Item-based kNN BM25 Sim.	0.999	0.992
Random	0.004	-0.064
Popularity	0.994	0.995

Figure: Tabla coeficientes de Pearson

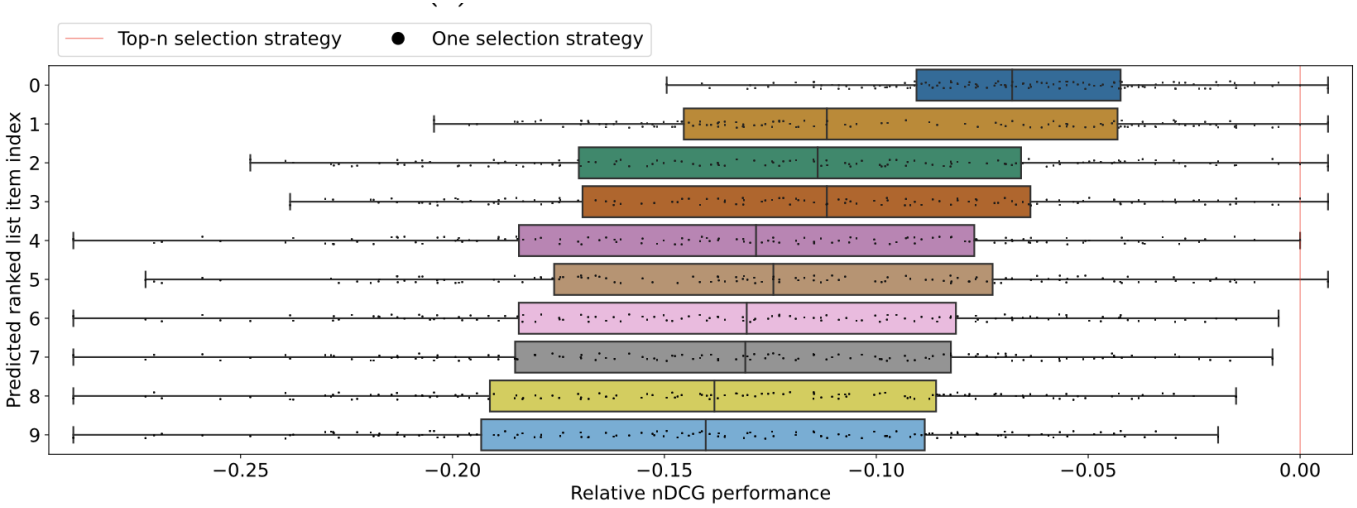

(b) *MovieLens-100k* data set.

Figure: Resultados nCDG relativo MovieLens

- De Implicit: Alternating Least Squares, Logistic Matrix Factorization, Bayesian Personalized Ranking y Item-Item Nearest Neighbors con las métricas de distancia Cosine Similarity, TF-IDF y BM25.
- De LensKit: Implicit Matrix Factorization, User-User Nearest Neighbors, Item-Item Nearest Neighbors, Most Popular y Random.

- Dominios: compras, música, películas y artículos, social y ubicaciones
- Conjuntos de datos de retroalimentación implícita: Adressa One Week, Citeulike-a, Cosmetics-Shop, Globo, Gowalla, Hetrec-Lastfm, Nowplaying-rs, Retailrocket[3], Sketchfab, Spotify-Playlists, Yelp y Yoochoose.
- Conjuntos de datos de retroalimentación explícita: Amazon CDsVinyl, Amazon Musical Instruments, Amazon Video Games, CiaoDVD, Jester3, MovieLens-1M, MovieLens-100k y MovieTweetings.